

А3. ИИ и машинное обучение в агроэкологическом мониторинге

Тип: Академический (бакалавриат/магистратура) · Связь: П3, П4 · Компоненты

FOLUR: 1, 2, 3 Пререквизиты: А1. Жизненный цикл данных, А2. Геоинформатика

Проект UNDP-KAZ FOLUR · Правило модуля: ИИ ускоряет — человек верифицирует.

О модуле

Модуль формирует полный цикл компетенций применения машинного обучения (ML) и искусственного интеллекта (ИИ) к задачам агроэкологического мониторинга: от поиска открытых спутниковых данных до обоснованного выбора архитектуры модели и честной оценки её качества. Логика модуля — «от инструмента к применению»: сначала данные и их подготовка, затем модели, затем критическое сравнение подходов на реальной региональной задаче — классификации землепользования Северного Казахстана.

Три подхода, которые сравнивает слушатель, покрывают три типовые производственные ситуации: **Random Forest** — когда данных мало и нужна интерпретируемость; **MiniRocket** — когда есть многолетние ряды NDVI/EVI и важна скорость; **CNN (U-Net, ResNet)** — когда есть снимки высокого разрешения, GPU и размеченный датасет.

Цели обучения

После прохождения модуля слушатель сможет:

1. **[Bloom: знать]** перечислять открытые источники данных дистанционного зондирования (Google Earth Engine, Microsoft Planetary Computer, Copernicus Data Space Ecosystem, архивы USGS/NASA — Landsat, MODIS, ASTER) и их ключевые характеристики (разрешение, периодичность, уровни обработки).
2. **[Bloom: понимать]** объяснять, как устроена подготовка обучающего датасета для ДЗЗ-задач (извлечение тайлов, разметка, аугментация, разбиение train/val/test) и почему пространственная утечка данных разрушает оценку качества модели.
3. **[Bloom: применять]** строить и валидировать модели трёх классов — Random Forest / Gradient Boosting, MiniRocket на временных рядах NDVI, CNN (U-Net, ResNet)

— на снимках Sentinel-2 по Северо-Казахстанской области, используя открытый стек (Python, scikit-learn, PyTorch, Colab).

4. **[Bloom: анализировать]** сравнивать три подхода по метрикам (F1, IoU, каппа Коэна), интерпретировать матрицу ошибок и обосновывать выбор архитектуры под конкретную задачу хозяйства или акимата.
5. **[Bloom: анализировать]** проводить ревью ML-кода, сгенерированного ИИ-агентом: находить утечки данных, ошибки метрик и методические дефекты пайплайна (уровень ИИ-слоя — pro-code).

Структура модуля

#	Урок	Тип	⌚ Трудозатраты
1	Находим и выгружаем обучающие данные: открытые каталоги ДЗЗ для ML-мониторинга	Лекция	~22 мин чтения + ~20 мин практики
2	Готовим датасет без утечек: от снимка Sentinel-2 к обучающей выборке	Лекция	~23 мин чтения + ~25 мин практики
3	Обучаем интерпретируемые модели: Random Forest, Gradient Boosting и MiniRocket на рядах NDVI	Лекция	~23 мин чтения + ~25 мин практики
4	Сегментируем снимки и выбираем архитектуру: CNN, метрики и честное сравнение трёх подходов	Лекция	~24 мин чтения + ~25 мин практики
5	Практикум: классификация землепользования района СКО тремя подходами	Guided-проект	60–90 мин
6	ИИ-ассистент в работе: аудит ML-пайплайна, собранного кодинг-агентом	ИИ-задание (pro-code)	45–60 мин

#	Урок	Тип	🕒 Трудозатраты
7	Итоговая оценка: банк вопросов и сценарный кейс	Оценивание	~30 мин

Суммарно: ≈2–2,5 часа контента в неделю на протяжении 2–3 недель (норматив платформы).

Прикладной продукт модуля

Классификация землепользования по Sentinel-2 для района Северо-Казахстанской области тремя подходами (RF / MiniRocket / CNN) со сравнительной таблицей метрик и обоснованием выбора архитектуры. Артефакты: Jupyter-ноутбук, карты классификации, таблица сравнения F1/каппа, краткое письменное обоснование.

ИИ-ассистент в работе · уровень Pro-code

Кодинг-агент (Claude Code / OpenCode) собирает ML-пайплайн «split → train → validate»; слушатель проводит ревью сгенерированного кода и целенаправленно ищет утечку данных и ошибки метрик. Задание и обязательный шаг верификации — в [ai-assistant.md](#). Рамка платформы — [ИИ-инструменты в обучении](#).

Правило: ИИ ускоряет — человек верифицирует. Все задания модуля выполнимы и без ИИ.

Связь с другими модулями (матрица А ↔ П)

- **A1** даёт источники данных и БПЛА-съёмку — здесь ортофотопланы БПЛА становятся входом для CNN (детекция сорняков, подсчёт растений).
- **A2** даёт проекции, растры и зональную статистику — здесь они используются при подготовке датасета.
- **A4** применяет ML-подходы модуля к водным объектам (обучающие выборки для моделей качества воды).
- **P3** — профессиональная «проекция» модуля: те же ИИ-задачи без программирования (готовые сервисы NDVI-мониторинга).
- **P4** — Python и Jupyter для специалистов: первый скрипт с ИИ-напарником.

Данные модуля

Только открытые и бесплатные источники: Sentinel-2 (Copernicus Data Space Ecosystem, Google Earth Engine, Microsoft Planetary Computer), Landsat/MODIS/ASTER (USGS/NASA), ESA WorldCover, OpenStreetMap, data.gov.kz. Политика данных платформы — [Датасеты](#). Ноутбуки практикума: Colab-ссылка — `<URL будет назначен при создании репозитория ноутбуков>`.

Оценивание

Квизы самопроверки после каждой лекции (автопроверяемые, формат платформы) + итоговый банк из 10 MCQ и сценарный кейс-вопрос ([assessment/final.md](#)). Порог сертификации — **75%**.

Библиография и рамки

Проверенные рамки и первичные источники (без выдуманных DOI; версии и годы — по официальным страницам):

1. **FAO. The 10 Elements of Agroecology** — рамка агроэкологического перехода; используется при интерпретации результатов мониторинга.
<https://www.fao.org/agroecology/overview/overview10elements/en/>
2. **WOCAT** (World Overview of Conservation Approaches and Technologies) — глобальная база технологий устойчивого землепользования; источник практик для интерпретации карт LULC. <https://www.wocat.net/>
3. **ЦУР 15.3 / LDN** (Land Degradation Neutrality, UNCCD) — индикатор 15.3.1 «доля деградированных земель»; ML-классификация землепользования — входной слой расчёта. <https://www.unccd.int/land-and-life/land-degradation-neutrality/overview>
4. **FOLUR Case Studies Catalogue, Vol. I (UNDP, декабрь 2025)** — каталог региональных кейсов программы FOLUR.
https://www.undp.org/sites/g/files/zskgke326/files/2026-01/folur_case_studies_catalogue_volume_i_final_december2025__0.pdf
5. Breiman L. *Random Forests*. Machine Learning, 2001 — первоисточник метода.
6. Dempster A., Schmidt D. F., Webb G. I. *MiniRocket: A Very Fast (Almost) Deterministic Transform for Time Series Classification*. KDD, 2021 — первоисточник метода.
7. Ronneberger O., Fischer P., Brox T. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI, 2015; He K. et al. *Deep Residual Learning for Image Recognition*. CVPR, 2016 — базовые архитектуры CNN.
8. Документация открытого стека: [scikit-learn](#), [PyTorch](#), [sktime](#), [Google Earth Engine](#), [Microsoft Planetary Computer](#), [Copernicus Data Space Ecosystem](#), [ESA WorldCover](#).



Научная честность

Все численные результаты моделей в модуле слушатель вычисляет сам — лекции не приводят «эталонных» значений точности, которых не существует до эксперимента. Непроверяемые утверждения помечаются [UNVERIFIED] .

Находим и выгружаем обучающие данные: открытые каталоги ДЗЗ для ML-мониторинга агроландшафтов

🕒 **Трудозатраты:** ~22 мин чтения + ~20 мин практики Модуль **A3: ИИ и машинное обучение в агроэкологическом мониторинге**, урок 1 из 4. Академический уровень. Проект UNDP-KAZ FOLUR. Компоненты FOLUR: **1, 2, 3**.

Цели лекции и место в модуле

Любая модель машинного обучения начинается не с кода, а с данных. В агроэкологическом мониторинге главный источник данных — открытые архивы дистанционного зондирования Земли (ДЗЗ), накопившие десятилетия наблюдений за каждым полем Северного Казахстана. Эта лекция учит ориентироваться в четырёх главных «воротах» к этим архивам и осознанно выбирать снимки под задачу машинного обучения: без правильно подобранных сцен не получится ни обучающая выборка (урок 2), ни модели (уроки 3–4).

После изучения лекции слушатель сможет:

1. **[Bloom: знать]** перечислять открытые каталоги ДЗЗ — Google Earth Engine (GEE), Microsoft Planetary Computer (MPC), Copernicus Data Space Ecosystem (CDSE), архивы USGS/NASA (Landsat, MODIS, ASTER) — и их ключевые характеристики.
2. **[Bloom: понимать]** объяснять различия уровней обработки (L1C/L2A), роль облачных масок и стандарта STAC в программном доступе к данным.
3. **[Bloom: применять]** составлять запрос к каталогу для отбора безоблачных сцен Sentinel-2 по территории и вегетационному сезону Северного Казахстана.
4. **[Bloom: анализировать]** сравнивать источники данных по разрешению, периодичности и условиям доступа и обосновывать выбор под конкретную ML-задачу.

Границы лекции. Внутри: открытые каталоги ДЗЗ, их сравнение, программный доступ, отбор сцен под ML-задачу. За рамками: физика съёмки, БПЛА и наземные сенсоры — это **модуль A1**; работа с растрами в QGIS и проекции — **модуль A2**; превращение выбранных сцен в обучающую выборку — **урок 2**; водные индексы и мониторинг водоёмов — **модуль A4**.

1. Зачем ML-мониторингу открытые данные

Задачи агроэкологического мониторинга, которые решает проект FOLUR в Северном Казахстане, по своей природе пространственно-временные: где расположены посевы и залежи, как меняется состояние пастбищ, где появляются очаги деградации.

Отвечать на такие вопросы вручную, объезжая поля, невозможно в масштабе области — типичный район Костанайской или Северо-Казахстанской области измеряется тысячами квадратных километров. Спутниковая съёмка решает проблему масштаба: каждые несколько дней сенсоры фиксируют состояние всей территории, а машинное обучение превращает поток снимков в карты и показатели.

Ключевое слово здесь — «открытые». Программы Copernicus (Европейский союз) и Landsat (США) публикуют данные бесплатно и без ограничений на использование, включая коммерческое. Это не техническая деталь, а фундамент всей архитектуры платформы FOLUR: обучение, практикумы и будущая работа хозяйств строятся на данных, за которые никто не платит и доступ к которым не может быть внезапно отозван поставщиком. Для учебного процесса и для малого агробизнеса это принципиально: тот же самый пайплайн, который студент собирает в бесплатном Colab, фермерское хозяйство может использовать без затрат на данные. Платные сверхвысокодетальные снимки (доли метра на пиксель) существуют и полезны, но в этом модуле они появляются только в сравнительных обзорах — весь практикум построен на открытом стеке.

Связь с программой FOLUR здесь прямая. Компонент 1 (интегрированное управление ландшафтами) требует актуальных карт землепользования — их производит классификация снимков. Компонент 2 (устойчивые практики) требует мониторинга состояния посевов и пастбищ — это временные ряды вегетационных индексов. Компонент 3 (восстановление) требует выявления деградированных участков и контроля динамики восстановления — это анализ многолетних архивов. Все три задачи начинаются с одного и того же шага, которому посвящена эта лекция: найти и корректно выгрузить открытые данные по своей территории.

Для машинного обучения открытость данных означает ещё одно: воспроизводимость. Обучающая выборка, собранная из открытого архива по опубликованному скрипту, может быть в точности пересобрана любым проверяющим. Это учебная дисциплина, которая позже станет производственной: заказчик (акимат, донор, аудитор) всегда вправе спросить, откуда взялись данные, на которых обучена модель.

1.1 Три роли снимка в ML-задаче

Прежде чем перечислять каталоги, зафиксируем, чем именно снимок служит в ML-пайплайне. Во-первых, снимок — источник **признаков** (features): значения спектральных каналов и вычисленных индексов (NDVI, EVI) становятся входом

модели. Во-вторых, снимок — основа **визуального дешифрирования** при разметке: эксперт смотрит на изображение и присваивает участку класс. В-третьих, серия снимков образует **временной ряд** — главный вход для моделей фенологической классификации культур, которыми мы займёмся в [уроке 3](#).

Эти три роли предъявляют разные требования. Для признаков важна радиометрическая корректность (атмосферная коррекция), для дешифрирования — наглядность и детальность, для временных рядов — регулярность и длина архива. Ни один источник не является лучшим сразу по всем трём осям, поэтому специалист держит в голове карту источников — её мы и строим дальше.

Подробнее о физических основах съёмки, спектральных каналах и сравнении спутников с БПЛА — в [модуле А1](#).

2. Карта открытых источников: спутники и их архивы

Начнём с самих данных, затем перейдём к каталогам-«воротам», через которые эти данные достаются.




Рис. 1. Карта открытых источников ДЗЗ: спутниковые программы (вверху) доступны через четыре каталога-«ворот» (в середине), из которых данные попадают в ML-пайплайн модуля. Alt: блок-схема, показывающая, что Sentinel-2, Landsat, MODIS и ASTER доступны через каталоги GEE, MPC, CDSE и USGS, а из каталогов данные идут в пайплайн машинного обучения.

2.1 Sentinel-2 — рабочая лошадка агромониторинга

Пара спутников Sentinel-2A/2B (программа Copernicus) снимает сушу в 13 спектральных каналах с разрешением 10 м (видимые и ближний ИК), 20 м (красный край, SWIR) и 60 м (атмосферные каналы). Совместный ревизит пары — порядка пяти дней, что в вегетационный сезон даёт достаточно шансов поймать безоблачную сцену. Архив ведётся с 2015 года. Для задач модуля Sentinel-2 — основной источник:

разрешение 10 м позволяет различать поля Северного Казахстана (они, как правило, крупные — сотни гектаров), а каналы красного края полезны для оценки состояния посевов.

Важная деталь — **уровни обработки**. L1C — отражение на верхней границе атмосферы (Top-of-Atmosphere), L2A — отражение у поверхности после атмосферной коррекции (Bottom-of-Atmosphere) плюс карта классификации сцены SCL, в которой размечены облака, тени и снег. Для машинного обучения выбирайте L2A: атмосферная коррекция уменьшает разброс значений между датами, а слой SCL — готовый инструмент маскирования облаков. Обучать модель на L1C можно, но тогда атмосферные искажения станут «шумовым признаком», который модель будет вынуждена выучивать.

2.2 Landsat — длина архива

Программа Landsat (USGS/NASA) — самый длинный непрерывный архив съёмки Земли: миссии с 1970–80-х годов по сегодняшний день, современные аппараты Landsat 8/9 дают 30 м в мультиспектре при ревизите 16 дней (8 дней для пары). Когда задача требует ретроспективы — «что было на этом участке двадцать лет назад, была ли это пашня или залежь» — Landsat незаменим: Sentinel-2 просто не существовал до 2015 года. Для анализа многолетней динамики землепользования, восстановления залежей и деградации пастбищ в лекциях [модуля А5](#) используется именно ретроспектива Landsat.

2.3 MODIS — ежедневная частота

Сенсор MODIS (спутники Terra и Aqua, NASA, с 2000 года) даёт грубое разрешение — 250 м для красного и ближнего ИК каналов, до 1000 м для остальных, — зато снимает всю территорию ежедневно. Готовые композитные продукты (например, 16-дневные композиты вегетационных индексов) — классический источник длинных, плотных и уже очищенных временных рядов NDVI/EVI. Когда в уроке 3 мы будем говорить о фенологических кривых культур, помните: для отдельного поля площадью в сотни гектаров пиксель MODIS 250 м часто целиком лежит внутри поля, и ряд получается чистым. Для мелких контуров MODIS уже слишком груб.

2.4 ASTER — рельеф и тематические задачи

Сенсор ASTER (на спутнике Terra) снимал по запросу с разрешением 15–90 м; для наших задач главное его наследие — глобальная цифровая модель рельефа ASTER GDEM, распространяемая свободно. Рельеф — полезный вспомогательный признак в классификации землепользования (уклоны влияют на распашку и эрозию) и ключевой вход гидрологических задач [модуля А4](#).

2.5 Вегетационные индексы: NDVI и EVI как производный слой

Прежде чем двигаться к каталогам, введём производный продукт, который будет сопровождать нас весь модуль. **NDVI** (Normalized Difference Vegetation Index) — нормализованная разность отражения в ближнем инфракрасном и красном каналах: $NDVI = (NIR - Red) / (NIR + Red)$. Здоровая зелёная растительность сильно отражает ближний ИК и поглощает красный, поэтому её NDVI высок; открытая почва и вода дают низкие или отрицательные значения. Индекс безразмерен и лежит в диапазоне от -1 до 1, что делает его удобным признаком для моделей: он частично снимает различия освещённости между датами.

EVI (Enhanced Vegetation Index) — усовершенствованный вариант с поправками на влияние почвы и атмосферы; он меньше «насыщается» на густой растительности, чем NDVI, и предпочтителен для плотных посевов в пик вегетации. Оба индекса вычисляются из каналов Sentinel-2 и Landsat одной строкой кода, а для MODIS распространяются как готовые композитные продукты.

Для машинного обучения индексы играют двойную роль. Во-первых, это компактные информативные признаки: вместо тринадцати каналов модель может получить два-три индекса, и для простых задач этого достаточно. Во-вторых, **сезонный ход индекса — фенологическая кривая** — является главным носителем информации о типе культуры: у яровой пшеницы, пара и залежи кривые NDVI за сезон различаются формой, даже когда отдельные снимки неразличимы. На этом свойстве целиком построен метод MiniRocket из [урока 3](#).

3. Четыре каталога-«ворот»: как достать данные

Данные едины, но путей к ним несколько, и выбор пути определяет архитектуру вашего пайплайна.

3.1 Google Earth Engine: вычисления рядом с данными

GEE — облачная платформа, в которой петабайтный каталог снимков совмещён с вычислительным кластером. Принципиальная идея: вы не скачиваете снимки, а отправляете код (JavaScript или Python API) туда, где данные лежат. Композит из сотен сцен Sentinel-2 за сезон по целой области считается на стороне Google за минуты — на ноутбуке такой расчёт потребовал бы скачать сотни гигабайт. Для некоммерческого использования и исследований доступ бесплатен (регистрация аккаунта обязательна); квоты на вычисления и экспорт существуют, и практикумы платформы спроектированы так, чтобы укладываться в бесплатные лимиты слушателя.

Для ML-задач GEE удобен на этапе подготовки данных: фильтрация коллекции по территории, датам и облачности, маскирование по SCL, расчёт индексов, медианные композиты, экспорт фрагментов. Обучение больших нейросетей внутри самой GEE не выполняется — обычный маршрут: подготовить массивы в GEE, выгрузить и обучать модель в Colab. Именно так устроен [практикум модуля](#).

Рабочая связка «GEE + Colab» заслуживает отдельного абзаца, потому что она станет вашей основной средой на весь модуль. Google Colab — бесплатная облачная среда Jupyter-ноутбуков: Python уже установлен, библиотеки ставятся одной командой, время от времени доступен GPU. Библиотека `geemap` соединяет две системы: авторизация в GEE прямо из ноутбука, интерактивная карта для просмотра композитов, функции выгрузки фрагментов в массивы NumPy. Слушатель работает под собственным аккаунтом и в рамках собственных квот — платформа не требует никакой серверной инфраструктуры, и это осознанное архитектурное решение: собранный вами пайплайн останется работоспособным и после окончания курса.

3.2 Microsoft Planetary Computer: STAC и открытый Python-стек

MPC — каталог открытых геоданных Microsoft со STAC-интерфейсом (см. § 3.5) и бесплатным доступом к данным. В отличие от GEE, MPC не навязывает собственный вычислительный API: вы работаете стандартным открытым Python-стеком — `pystac-client` для поиска, `stackstac / rioxarray` для загрузки, `xarray` и `dask` для ленивых вычислений. Это делает код переносимым: тот же скрипт с минимальными правками работает с любым STAC-каталогом, не только с MPC. Для слушателя это страховка от привязки к вендору — одному из рисков, о которых честно говорит [рамка ИИ-инструментов платформы](#).

3.3 Copernicus Data Space Ecosystem: официальный источник

CDSE — официальная точка распространения данных Copernicus (Sentinel-1/2/3/5P): браузерный поиск, OData/STAC API, процессинговые сервисы. Когда нужен гарантированно полный и свежий архив Sentinel-2 «из первых рук» — идти сюда. Регистрация бесплатна, месячные квоты на скачивание для обычного аккаунта достаточны для учебных задач. CDSE также даёт доступ к продуктам Sentinel-1 (радар) — они понадобятся в [модуле A4](#) для мониторинга паводков.

3.4 USGS EarthExplorer и NASA Earthdata: американские архивы

EarthExplorer — портал Геологической службы США: Landsat всех поколений, декадные архивы аэрофотосъёмки, ASTER. NASA Earthdata открывает продукты MODIS и множество производных научных наборов. Оба требуют бесплатной регистрации. Программный доступ возможен (API M2M у USGS, `earthaccess` у NASA), но для наших

задач Landsat и MODIS удобнее забирать через GEE или MPC, где они уже лежат в аналитически готовом виде.

3.5 STAC: общий язык каталогов

SpatioTemporal Asset Catalog (STAC) — открытый стандарт описания пространственно-временных данных: каждая сцена описывается JSON-документом с геометрией, датой, облачностью и ссылками на файлы-активы. Единый стандарт означает единый код поиска: научившись формировать STAC-запрос («территория — такой-то полигон, даты — май–сентябрь, облачность < 20%»), вы одинаково работаете с MPC, CDSE и десятками других каталогов. Для инженера ML-систем STAC — такой же базовый навык, как SQL для аналитика данных.

3.6 Вспомогательные векторные данные: OSM и data.gov.kz

ML-пайплайну нужны не только растры. Границы административных единиц, контуры полей, дороги и населённые пункты — векторные данные, которые задают область интереса, помогают в разметке и служат маской для исключения нерелевантных территорий. Два открытых источника закрывают большинство потребностей.

OpenStreetMap — глобальная краудсорсинговая база: административные границы, гидрография, дороги; выгружается через Overpass API или готовые региональные выгрузки. **data.gov.kz** — портал открытых данных Республики Казахстан: справочники административно-территориального деления и тематические наборы государственных органов; состав и актуальность наборов различаются, поэтому перед использованием проверяйте дату обновления и полноту конкретного набора.

Практическое правило: векторные границы из любого источника перед использованием визуально сверяются с актуальным снимком. Границы района, оцифрованные несколько лет назад, могли устареть; контур поля из OSM мог быть нарисован неточно. Навыки работы с векторными данными и их приведения к общей проекции с растрами дал [модуль A2](#) — здесь мы ими пользуемся как готовым инструментом.

3.7 Сравнительная таблица

Критерий	GEE	MPC	CDSE	USGS/NASA
Модель работы	код к данным (свой API)	STAC + открытый Python-стек	официальный архив, OData/STAC	порталы + API

Критерий	GEE	MPC	CDSE	USGS/NASA
Sentinel-2	да	да	да (первоисточник)	нет
Landsat / MODIS / ASTER	да / да / частично	да / да / нет	нет	да (первоисточник)
Вычисления на стороне сервера	да	частично (кластеры)	сервисы обработки	нет
Стоимость для учёбы	бесплатно (регистрация)	бесплатно	бесплатно (квоты)	бесплатно
Риск привязки к вендору	выше (свой API)	ниже (открытый стек)	низкий	низкий

Практический вывод: **в этом модуле — GEE для быстрой подготовки данных, MPC/STAC как переносимая альтернатива, CDSE как первоисточник, USGS/NASA для ретроспективы.** Умение работать минимум с двумя воротами — требование к выпускнику.

4. Отбор сцен под ML-задачу: облачность, сезон, уровень обработки

Каталог найден — теперь надо правильно спросить. Три фильтра определяют качество будущей выборки.

Территория и проекция. Область интереса (AOI) задаётся полигоном — границей района, хозяйства или тестового участка. Источники границ — OpenStreetMap и открытые данные data.gov.kz; о проекциях и подготовке полигонов подробно рассказывал [модуль A2](#). Помните, что Sentinel-2 распространяется тайлами по 110 км: район на стыке тайлов потребует мозаики.

Время и фенология. Для Северного Казахстана вегетационный сезон яровых культур укладывается примерно в май–сентябрь: сев поздней весной, пик вегетации в середине лета, уборка к осени. Классификация культур по единственному снимку ненадёжна — в отдельные даты пшеница, ячмень и залежь выглядят почти

одинаково; различия проявляются в **динамике** отражения за сезон. Поэтому под задачу классификации культур отбирают серию сцен за сезон, а под задачу «пашня/не пашня» бывает достаточно двух-трёх удачных дат.

Облачность. Метаданные каждой сцены содержат оценку облачного покрытия; фильтр «облачность < 20–30%» — типовая отправная точка. Но общая облачность сцены не гарантирует чистоту вашего участка: облако могло встать ровно над ним. Поэтому после грубого фильтра применяют попиксельное маскирование по слою SCL (для L2A) и собирают **композит** — например, медиану по времени из всех чистых пикселей за период. Медианный композит устойчив к остаточным облакам и теням и является стандартной заготовкой для классификации землепользования.

Типовой запрос в GEE Python API выглядит так:

```
import ee
ee.Initialize()

aoi = ee.Geometry.Polygon(coords_of_district) # граница района из
OSM/data.gov.kz

s2 = (ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED') # L2A
      .filterBounds(aoi)
      .filterDate('2023-05-01', '2023-09-30')
      .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 30)))

def mask_scl(img):
    scl = img.select('SCL')
    good = scl.remap([4, 5, 6, 7], [1, 1, 1, 1], 0) # вегетация, почва, вода,
unclassified
    return img.updateMask(good)

composite = s2.map(mask_scl).median().clip(aoi)
```

Каждая строка соответствует шагу из этого раздела: границы AOI, окно дат под фенологию, грубый фильтр облачности, попиксельная маска SCL, медианный композит. В **практикуме** вы выполните этот код на реальном районе СКО.

4.1 Планирование объёма данных и квот

Прежде чем нажимать «выполнить», полезно прикинуть объём. Один тайл Sentinel-2 L2A — порядка гигабайта; сезон из двадцати дат по району, покрываемому двумя тайлами, — уже десятки гигабайт исходных данных. Отсюда три практических следствия. Первое: **фильтруйте и обрезайте как можно раньше** — сначала пространственный и временной фильтр, затем выбор только нужных каналов, и лишь потом вычисления. Второе: **выгружайте производные, а не исходники** — медианный композит из шести каналов по району на порядки меньше полного архива сцен; для обучения моделей в Colab обычно достаточно выгрузить массивы признаков и меток, а не снимки целиком. Третье: **уважайте квоты** — бесплатные лимиты GEE и CDSE

рассчитаны на разумную исследовательскую нагрузку; пайплайн, повторно скачивающий одни и те же данные в цикле, — признак плохой архитектуры, а не недостатка квот. Кэшируйте промежуточные результаты (в Colab — на подключённый Google Drive слушателя).

Эти привычки — часть инженерной культуры работы с данными, которую **модуль A1** описывал принципами FAIR: находимость, доступность, интероперабельность, переиспользуемость. Каталоги обеспечивают первые две буквы; за последние две отвечает ваш пайплайн.

Подробнее о том, как из композита и рядов NDVI собрать обучающую выборку, — в **уроке 2**.

5. Что каталоги не решают: ответственность аналитика

Открытые каталоги сняли проблему доступа, но не сняли ответственность за смысл. Во-первых, **пространственное разрешение задаёт предел различимости**: на пикселе 10 м не видно отдельных растений и узких лесополос — для них нужен БПЛА (**модуль A1**). Во-вторых, **автоматические маски облаков ошибаются**: SCL иногда путает яркую почву со облаком и пропускает полупрозрачную дымку — выборочная визуальная проверка сцен обязательна. В-третьих, **архивы неоднородны**: сенсоры Landsat разных поколений отличаются, и «сшивая» ряд из разных миссий, нужно учитывать различия калибровки. Наконец, любые готовые продукты (композиты, карты покрытия) созданы под чужие задачи и требуют валидации на вашей территории — эта мысль станет центральной в уроке 2 при разговоре о разметке.

Здесь впервые встречается главный инвариант платформы: **ИИ и автоматика ускоряют, человек верифицирует**. Автоматический фильтр отбирает сцены за секунды, но подтверждает их пригодность аналитик — глазами, по контрольным участкам.

Соберём ответственность аналитика в контрольный список, который стоит проходить перед каждой выгрузкой данных под ML-задачу:

- **Задача → разрешение.** Минимальный различимый объект задачи (поле? лесополоса? отдельное растение?) сопоставлен с размером пикселя выбранного источника.
- **Задача → архив.** Требуемая глубина ретроспективы сопоставлена с началом архива (Sentinel-2 — 2015, MODIS — 2000, Landsat — 1980-е).
- **Уровень обработки.** Для признаков модели выбран атмосферно скорректированный уровень (L2A и аналоги).
- **Маскирование.** Применена попиксельная маска облаков; выборочно проверены глазами 3–5 сцен из разных месяцев.

- **Композит или ряд.** Продукт (одиночный композит / помесечная серия / плотный ряд индексов) соответствует тому, что реально различает классы задачи.
- **Воспроизводимость.** Запрос сохранён как код с зафиксированными датами, фильтрами и версией коллекции — коллега может пересобрать те же данные.

Список короткий, но каждая его строка — это реальный класс ошибок, с которыми сталкиваются производственные проекты мониторинга. В [уроке 2](#) к нему добавится вторая половина — контроль качества меток и разбиения выборки.

Региональный кейс

Ситуация: Агроконсультационная служба готовит для акимата одного из районов Северо-Казахстанской области основу под карту землепользования сезона 2023 года. Нужен безоблачный композит Sentinel-2 за вегетационный сезон и оценка того, сколько пригодных сцен вообще было над районом — от этого зависит, удастся ли строить классификацию по временному ряду или придётся ограничиться одним композитом.

Данные: коллекция `COPERNICUS/S2_SR_HARMONIZED` (Sentinel-2 L2A) в Google Earth Engine; граница района — из OpenStreetMap (`geoBoundaries/OSM administrative boundaries`); период 1 мая — 30 сентября 2023 г.

Задача:

1. Составьте (на бумаге или в Colab) цепочку фильтров GEE: территория → даты → облачность < 30%. Сколько сцен возвращает фильтр? (`collection.size()`)
2. Постройте помесечную статистику: в каком месяце чистых сцен меньше всего? Что это означает для классификации культур по фенологии?
3. Сравните два варианта продукта для акимата: медианный композит за весь сезон и серия помесечных композитов. Какой из них годится для карты «пашня/пастбище/залежь», а какой — для различения культур?

Разбор: Ключевой ход — отделить *количество сцен* от *количества чистых наблюдений на пиксель*: даже при десятках сцен конкретное поле может иметь мало безоблачных дат, поэтому правильная метрика — попиксельный счётчик чистых наблюдений (`count()` после маски SCL). Для карты укрупнённых классов достаточно одного сезонного медианного композита; для различения культур нужны помесечные композиты или ряд NDVI, потому что классы различаются динамикой, а не единственным значением.

Второй важный вывод касается коммуникации с заказчиком: отчёт для акимата должен явно фиксировать, из каких дат собран композит и какова была доступность

чистых наблюдений по месяцам, — иначе карта, построенная на «дырявом» июне, будет воспринята как равнонадёжная на всей территории. Честная карта покрытия наблюдениями — такой же продукт анализа, как и сама карта землепользования. Конкретные числа сцен слушатель получает сам при выполнении — лекция намеренно не приводит «готовых ответов», их не существует до запроса.

Этот кейс продолжается в **практикуме**: там композит и ряды NDVI строятся полностью и становятся входом трёх моделей.

Закрепление и применение

Попробуйте в Colab

Откройте ноутбук урока (<URL будет назначен при создании репозитория ноутбуков>), авторизуйтесь в GEE и выполните запрос из § 4 для своего района: посчитайте число сцен за сезон и постройте медианный композит. Затем повторите тот же поиск через STAC-запрос к Microsoft Planetary Computer и сравните списки сцен — они должны совпадать с точностью до задержек публикации.

Границы применимости

Открытые данные 10–30 м не решают задач уровня отдельных растений (сорняки, всходы) — это зона БПЛА из модуля А1. Оценка облачности в метаданных — грубая; без попиксельной маски и визуальной проверки композит может содержать артефакты. Бесплатные квоты GEE/CDSE рассчитаны на исследование и учёбу; промышленный конвейер потребует планирования нагрузки.

Что это даёт вашему хозяйству

Умение самостоятельно достать безоблачный композит по своим полям — это отказ от «слепой» зависимости от готовых сервисов: вы видите те же данные, что и любая платная платформа NDVI-мониторинга, и можете проверять её выводы. Профессиональная версия этого навыка без программирования — **модуль П3**.

? Кейс для размышления

Хозяйству нужно понять, когда сосед распахал прилегающую залежь — событие произошло между 2016 и 2020 годом. Какой источник данных вы выберете и почему: Sentinel-2 (с 2015, 10 м), Landsat (с 1980-х, 30 м) или MODIS (с 2000, 250 м)? Что если событие произошло между 2005 и 2010 годом?

Проверь себя

Самопроверка · вариант слушателя **конспект** · вопросов: 4 · порог зачёта: 75%

1. Фильтр «облачность сцены < 30%» пропустил сцену, где облако стоит ровно над вашим полем. Какой шаг пайплайна боится от этого?

- ☐ Попиксельное маскирование по слою SCL и медианный композит по времени
- ☐ Уменьшение области интереса до границ одного поля
- ☐ Переход с L2A на L1C
- ☐ Ужесточение фильтра до «облачность < 5%»

2. Почему для обучающей выборки ML рекомендуется уровень обработки Sentinel-2 L2A, а не L1C?

- ☐ L1C распространяется платно, а L2A — бесплатно
- ☐ L2A имеет более высокое пространственное разрешение, чем L1C
- ☐ L2A обновляется чаще, чем L1C
- ☐ L2A прошёл атмосферную коррекцию и содержит слой SCL для маскирования облаков

3. Для ретроспективного вопроса «была ли эта земля пашней в 1995 году» подходит только один источник. Какой и почему?

- ☐ Landsat — его непрерывный архив тянется с 1970–80-х годов
- ☐ ASTER GDEM — он покрывает весь мир
- ☐ Sentinel-2 — у него лучшее разрешение (10 м)
- ☐ MODIS — он снимает ежедневно

4. Зачем инженеру ML-систем стандарт STAC, если есть удобный API Google Earth Engine?

- ☐ STAC автоматически исправляет ошибки облачных масок
- ☐ STAC работает быстрее любого проприетарного API
- ☐ STAC — открытый стандарт, единый для многих каталогов: код поиска переносим и не привязан к одному вендору
- ☐ Через STAC данные доступны без регистрации

Проверить

Контрольные вопросы

1. Перечислите четыре каталога-«ворот» к открытым данным ДЗЗ и по одной сильной стороне каждого. (*Bloom: знать*)
2. Объясните, почему медианный композит устойчив к остаточной облачности. (*Bloom: понимать*)
3. Составьте план отбора сцен для классификации культур в вашем районе Акмолинской области: источник, период, фильтры, продукт. (*Bloom: применять*)

Что дальше?

В уроке 2 «Готовим датасет без утечек» отобранные сцены превратятся в обучающую выборку: вы узнаете, откуда берутся метки классов, зачем нужна аугментация и почему случайное перемешивание пикселей перед разбиением train/test — самая дорогая ошибка геопространственного ML. Связанные материалы: [политика датасетов платформы](#), [модуль A2 — растры и проекции](#), [модуль ПЗ — те же данные без кода](#).

Готовим датасет без утечек: от снимка Sentinel-2 к обучающей выборке

🕒 **Трудозатраты:** ~23 мин чтения + ~25 мин практики Модуль **A3: ИИ и машинное обучение в агроэкологическом мониторинге**, урок 2 из 4. Академический уровень. Проект UNDP-KAZ FOLUR. Компоненты FOLUR: **1, 2, 3**.

Цели лекции и место в модуле

Качество модели машинного обучения ограничено сверху качеством обучающей выборки — этот принцип не имеет исключений. В **уроке 1** мы научились доставать снимки из открытых каталогов; теперь предстоит превратить их в датасет: выбрать представление данных, добыть метки классов, нарезать тайлы, при необходимости расширить выборку аугментацией и — самое ответственное — правильно разбить её на обучающую, валидационную и тестовую части. Именно на последнем шаге совершается самая дорогая ошибка геопространственного ML — пространственная утечка данных, из-за которой модель выглядит блестяще на бумаге и проваливается на реальной территории.

После изучения лекции слушатель сможет:

1. **[Bloom: знать]** перечислять три представления ДЗЗ-данных для ML (пиксельная таблица, тайлы, временные ряды), источники меток и основные фреймворки открытого стека (scikit-learn, PyTorch, TensorFlow, Hugging Face).
2. **[Bloom: понимать]** объяснять механизм пространственной утечки данных и её влияние на оценку качества модели.
3. **[Bloom: применять]** собирать обучающую выборку по композиту Sentinel-2 с метками из открытых карт покрытия и корректным пространственным разбиением.
4. **[Bloom: анализировать]** оценивать качество меток и схему разбиения чужого (в том числе сгенерированного ИИ) пайплайна и находить в них дефекты.

Границы лекции. Внутри: представления данных, разметка, аугментация, разбиение, обзор фреймворков. За рамками: сами алгоритмы — Random Forest и MiniRocket в **уроке 3**, CNN в **уроке 4**; поиск и выгрузка снимков — **урок 1**; полевые методы сбора наземных данных — **модуль A1**.

1. Анатомия обучающей выборки: три представления данных

Формально обучающая выборка — это множество пар «объект → метка»: модель учится предсказывать метку по признакам объекта. В дистанционном зондировании «объектом» могут быть три принципиально разные сущности, и выбор между ними — первое проектное решение любой задачи.

Пиксельная таблица. Объект — отдельный пиксель; признаки — значения спектральных каналов и индексов в этом пикселе (возможно, за несколько дат); метка — класс землепользования. Получается обычная таблица «строки × столбцы», с которой работают классические алгоритмы вроде Random Forest. Достоинства: простота, скромные требования к объёму данных, интерпретируемость признаков. Ограничение: модель не видит пространственный контекст — пиксель посреди поля и пиксель у кромки лесополосы для неё различаются только спектром.

Тайлы (патчи). Объект — квадратный фрагмент снимка, например 64×64 или 256×256 пикселей; метка — либо класс всего фрагмента (классификация, архитектуры типа ResNet), либо попиксельная маска классов (сегментация, архитектуры типа U-Net). Тайлы сохраняют пространственный контекст — текстуру, форму границ, соседства объектов — и являются родным форматом свёрточных нейросетей. Плата: нужен большой размеченный набор и вычислительные ресурсы.

Временные ряды. Объект — последовательность значений (чаще всего NDVI/EVI) для одной точки или одного поля за сезон или несколько лет; метка — культура или тип использования. Это представление напрямую кодирует фенологию — то самое свойство, которое различает яровую пшеницу, пар и залежь, неотличимые на единственном снимке. С рядами работают специализированные методы, в нашем модуле — MiniRocket.




Рис. 1. Путь от снимка к обучающей выборке: композит и метки соединяются в одном из трёх представлений (таблица, тайлы, ряды), после чего выборка проходит пространственное разбиение. Alt: блок-схема подготовки датасета — входные снимки и

метки преобразуются в пиксельные таблицы, тайлы или временные ряды, затем разбиваются на *train/val/test* и передаются моделям.

Обратите внимание: все три представления собираются из **одних и тех же** исходных сцен. В **практикуме** вы построите все три из одного композита и одной серии NDVI — это и позволит честно сравнить три подхода на общем материале.

1.1 Сколько данных нужно?

Универсального числа не существует, но есть устойчивые ориентиры, связанные с ёмкостью моделей. Классическим алгоритмам на пиксельной таблице (Random Forest) для укрупнённых классов часто достаточно сотен–тысяч примеров на класс — при условии, что примеры репрезентативны, то есть охватывают разнообразие класса по почвам, влажности и стадиям вегетации. Методам временных рядов нужны сотни размеченных рядов на класс. Свёрточные сети прожорливее всех: обучение с нуля осмысленно от тысяч тайлов, и именно поэтому в глубоких подходах так ценятся аугментация (§ 3.2) и дообучение предобученных моделей (§ 5).

Важнее абсолютного размера — покрытие изменчивости. Тысяча пикселей из одного поля несёт меньше информации, чем сто пикселей из ста разных полей: первые почти дубликаты. Планируя разметку, распределяйте усилия по территории и по градиентам условий (север–юг района, разные почвенные разности, разные хозяйства), а не концентрируйте их там, где размечать удобно. Этот принцип называют репрезентативностью выборки, и его нарушение не лечится алгоритмами.

Подробнее о том, какой алгоритм соответствует какому представлению, — в **уроке 3** и **уроке 4**.

2. Откуда берутся метки: три источника и их честность

Метки — самая дорогая часть датасета: снимки бесплатны и бесконечны, а знание «что на самом деле растёт на этом поле» стоит времени и экспертизы. Три источника меток образуют лестницу «дороже и точнее ↔ дешевле и шумнее».

2.1 Полевые данные — золотой стандарт

Наземные обследования — GPS-точки с зафиксированным классом, журналы севооборотов хозяйств, акты обследования угодий — дают самые надёжные метки. Требования к полевому сбору данных (координаты, время, условия — обязательные атрибуты каждого замера) подробно разобраны в **модуле A1** и профессиональном **модуле П1**. Ограничение очевидно: полевые данные покрывают точки, а не территории, их сбор медленный и дорогой. В учебном практикуме мы полевых данных не имеем — и честно это фиксируем.

Отдельно подчеркнём ценность данных самих хозяйств: журнал севооборота — это готовые метки культур на уровне целых полей за много лет, то есть именно то, чего не даёт ни одна глобальная карта. Партнёрство «хозяйство даёт историю полей — аналитик даёт модель» — типовая схема региональных проектов агромониторинга, и слушатели профессиональных модулей часто приходят именно с такими данными. Юридическая и этическая сторона передачи таких данных (кому принадлежат, как обезличивать) обсуждалась в [модуле A1](#).

2.2 Визуальное дешифрирование — экспертная разметка по снимку

Эксперт смотрит на снимок (и вспомогательные слои — многолетние композиты, рельеф) и вручную обводит эталонные участки классов. Это стандартная практика создания обучающих полигонов: аналитик с региональным опытом уверенно отличает пашню от пастбища и водоёма по текстуре, цвету и контексту. Качество зависит от квалификации и дисциплины: эталоны должны быть *чистыми* (внутри полигона — только один класс), *репрезентативными* (охватывать разнообразие класса — разные почвы, стадии вегетации) и *задокументированными* (кто, когда, по какому снимку размечал). Разметка по снимку одной даты рискованна для «динамических» классов: залежь в июне легко спутать с пастбищем — эксперт обязан смотреть сезонную серию.

2.3 Готовые карты покрытия — быстро, но с оговорками

Глобальные карты землепользования — **ESA WorldCover** (10 м, классы «пашня», «травянистая растительность», «вода» и др.) и аналогичные открытые продукты — позволяют получить тысячи меток за минуты: пересекаем карту с нашим композитом и читаем класс каждого пикселя. Это легальный и распространённый приём бутстрапа выборки, но у него три подводных камня, каждый из которых обязан быть проговорён в отчёте.

Во-первых, **чужие ошибки становятся вашими**: глобальная карта сама построена моделью и содержит ошибки классификации, которые ваша модель выучит как «истину». Во-вторых, **несовпадение года**: карта фиксированного года не отражает последующие изменения — распаханную залежь или заброшенное поле. В-третьих, **несовпадение легенды**: классы глобальной карты («cropland») не совпадают с нужными вам («яровая пшеница» / «пар» / «залежь») — глобальная карта в принципе не может дать метки культур. Отсюда рабочее правило модуля: готовые карты — источник **черновых** меток укрупнённых классов, которые обязательно проходят выборочную визуальную верификацию, а для тонких классов (культур) метки добываются дешифрированием сезонной динамики или полевыми данными.

Минимальный протокол документирования разметки, принятый в модуле, укладывается в короткую таблицу, сопровождающую каждый набор эталонов:

Поле протокола	Что фиксируем
Источник метки	поле / дешифрирование / готовая карта (какая, какого года)
Опорные материалы	композит (даты), серия NDVI, рельеф
Автор и дата	кто размечал, когда
Правила класса	письменное определение каждого класса легенды
Верификация	доля проверенных меток, процент расхождений

Пять строк дисциплины превращают «набор полигонов на диске» в научный артефакт: коллега (или вы через полгода) сможет понять, чему верить. Требование задокументированной легенды — самое недооценённое: половина споров «модель ошиблась» на поверку оказывается спором о том, что считать залежью.

2.4 Шум в метках и что с ним делать

Даже аккуратная разметка содержит шум: смешанные пиксели на границах полей, устаревшие контуры, человеческие ошибки. Практические приёмы снижения вреда: буферный отступ от границ полигонов (не брать краевые пиксели), контроль согласованности (пиксели одного полигона со «странным» спектром — кандидаты на исключение), перекрёстная разметка спорных участков двумя экспертами. И главное — **оценка качества модели должна выполняться на самых чистых метках, какие есть**: допустимо обучаться на шумных метках из готовой карты, но тестовый набор стоит верифицировать вручную, иначе вы измеряете согласие двух моделей, а не качество вашей.

Полезно понимать и асимметрию последствий: умеренный случайный шум в обучающих метках модели переносят сравнительно стойко — ансамбли деревьев и нейросети усредняют случайные ошибки. Опасен шум *систематический*: если все залежи в выборке помечены как пастбища, никакой алгоритм не восстановит несуществующий класс, а метрики даже не просигналят о проблеме, потому что тест унаследовал ту же ошибку. Отсюда порядок приоритетов при ограниченном времени: сначала — чистота легенды и теста, затем — объём обучающей выборки, и лишь потом — тонкая настройка моделей.

3. Извлечение тайлов и аугментация

3.1 Нарезка тайлов

Для CNN снимок нарезается на тайлы фиксированного размера. Технически это скользящее окно по растру: шаг равен размеру тайла (без перекрытия) или меньше его (с перекрытием — больше примеров, но соседние тайлы сильно коррелированы, что важно учесть при разбиении, см. § 4). Каждому тайлу сопоставляется метка: класс центрального пикселя, преобладающий класс, или полная маска для сегментации. Практические мелочи, экономящие часы отладки: тайлы с большой долей замаскированных (облачных) пикселей отбрасываются; значения каналов приводятся к плавающему типу и разумному диапазону; геопривязка каждого тайла сохраняется в метаданных — без неё вы не сможете ни собрать карту из предсказаний, ни выполнить пространственное разбиение.

Выбор размера тайла — компромисс между контекстом и статистикой. Крупный тайл (256×256 при 10 м — это 2,56 км стороны) даёт сети богатый контекст: видны целые поля с границами и соседствами, но таких тайлов из района получится немного, а метка «один класс на тайл» становится сомнительной — внутри почти наверняка несколько классов. Мелкий тайл (32×32, 320 м) даёт тысячи примеров с чистыми метками, но лишает сеть дальнего контекста. Для сегментации (U-Net) проблема мягче — метка попиксельная, и размер тайла выбирается из соображений памяти GPU; для классификации целых тайлов (ResNet) чистота метки критична, и размер подбирают под характерный размер объектов ландшафта. В зерновом поясе Северного Казахстана с его крупными массивами разумно начинать с 64×64 и корректировать по результатам анализа ошибок (урок 4).

3.2 Аугментация: расширяем выборку без новых данных

Аугментация — порождение новых обучающих примеров преобразованием существующих. Для снимков естественны геометрические преобразования: повороты на 90°/180°/270°, отражения — спутниковый снимок не имеет «верха», поэтому повёрнутое поле остаётся полем. Осторожнее с радиометрией: лёгкое варьирование яркости имитирует различия освещённости, но агрессивные цветовые искажения могут разрушить спектральную информацию, на которой держится различие классов — в отличие от обычных фотографий, в ДЗЗ точные значения каналов несут физический смысл.

Два правила без исключений. Первое: **аугментация применяется только к обучающей части** — валидационные и тестовые данные остаются нетронутыми, иначе оценка качества искажается. Второе: аугментация не лечит систематические пробелы выборки — если в ней нет ни одного примера солончака, никакие повороты его не породят; лечится это только сбором данных. Для временных рядов и пиксельных таблиц аугментация используется реже; типовой приём для рядов — небольшие сдвиги по времени, имитирующие межгодовые сдвиги фенологии.

3.3 Дисбаланс классов

В реальных агроландшафтах Северного Казахстана классы радикально не равны по площади: пашня занимает огромные массивы, а, скажем, водные объекты или лесополосы — проценты территории. Модель, обученная на несбалансированной выборке «как есть», научится игнорировать редкие классы — и при этом покажет высокую *общую* точность (об этой ловушке метрик — [урок 4](#)). Стандартные меры: стратифицированный отбор (фиксированное число примеров каждого класса), взвешивание классов в функции потерь, передискретизация редких классов. Что выбрать — зависит от алгоритма и задачи; важно одно: решение о балансировке принимается осознанно и документируется.

4. Разбиение выборки: где живёт утечка данных

4.1 Зачем три части

Стандартная схема: **train** — на этих данных модель учится; **validation** — на них подбираются гиперпараметры и принимаются решения «какая архитектура лучше»; **test** — неприкосновенный набор, к которому обращаются один раз, для финальной оценки. Смешение ролей обесценивает оценку: если тест участвовал в выборе модели, он уже не независим, и настоящее качество на новых данных окажется ниже измеренного.

Когда данных мало, вместо фиксированного валидационного набора применяют **кросс-валидацию**: выборка делится на K блоков, модель обучается K раз, каждый раз откладывая один блок на проверку, а оценкой служит среднее по K прогонам. Кросс-валидация использует данные экономнее и даёт представление о разбросе оценки, но правило пространственности распространяется и на неё: блоки должны формироваться из территориальных групп, а не из случайных пикселей — иначе K честных на вид прогонов дадут K одинаково завышенных оценок. Тестовый набор при этом всё равно остаётся отдельным и неприкосновенным: кросс-валидация — инструмент выбора модели, а не финального вердикта.

4.2 Пространственная автокорреляция — почему случайное разбиение лжёт

Первый закон географии Тоблера: близкие объекты похожи сильнее далёких. Соседние пиксели одного поля почти идентичны — тот же сорт, та же почва, та же дата съёмки. Теперь проследите, что делает **случайное** разбиение пиксельной таблицы: соседние, практически одинаковые пиксели одного поля разлетаются — один в **train**, другой в **test**. Модель «узнаёт» на тесте примеры, неотличимые от обучающих, и оценка качества взлетает. Это и есть **пространственная утечка данных** (spatial leakage): информация из теста просочилась в обучение через пространственную корреляцию. Модель при этом не стала лучше — лучше стала только цифра в отчёте.

На новом районе, где нет «близнецов» из обучающей выборки, качество упадёт — иногда драматически. Величину падения вы измерите сами в [практикуме](#) и в [ИИ-задании](#); лекция сознательно не называет числа — оно зависит от данных.

Лекарство — **пространственное разбиение**: делим не пиксели, а *территории*. Варианты: разбиение по полигонам разметки (все пиксели одного полигона — целиком в одной части), по полям, по квадратам регулярной сетки, по географическим блокам («запад района — обучение, восток — тест»). В scikit-learn для этого есть групповые схемы (`GroupKFold`, `GroupShuffleSplit`), где группа — идентификатор поля/полигона/ячейки сетки. Для тайлов с перекрытием группировка обязательна вдвойне: перекрывающиеся тайлы — почти дубликаты.

4.3 Другие маршруты утечки

Пространство — не единственный канал. **Утечка через предобработку**: параметры нормализации (среднее, дисперсия), вычисленные по *всей* выборке до разбиения, несут информацию о тесте; правильно — вычислять статистики только по train и применять к остальным частям (в scikit-learn это автоматизирует `Pipeline`).

Временная утечка: если задача — прогноз, обучение на данных «из будущего» относительно теста обесмысливает оценку. **Утечка через метку**: признак, производный от целевой переменной (например, класс из той же готовой карты, из которой взяты метки, поданный как входной признак), даёт модели ответ в условии задачи. **Утечка через дубликаты**: одна и та же территория, попавшая в выборку дважды через разные сцены.

Эти маршруты — не экзотика, а типовые дефекты реальных пайплайнов, в том числе сгенерированных ИИ-агентами: код с `train_test_split(X, y, random_state=42)` на пиксельной таблице выглядит образцово и при этом протекает. Поиск таких дефектов в сгенерированном коде — ваше [ИИ-задание модуля](#).

4.4 Как проверить чужой пайплайн на утечки

Умение находить утечки в чужом коде — отдельный профессиональный навык, и он тренируется системно, а не интуицией. Порядок досмотра, который мы будем применять в [ИИ-задании](#):

1. **Найдите строку разбиения.** Какая функция делит данные? Есть ли в ней параметр групп (`groups=`)? Если это простой `train_test_split` на пиксельных данных — почти наверняка утечка.
2. **Проследите происхождение каждого признака.** Не участвует ли в признаках источник, из которого взяты метки? Нет ли признаков «из будущего»?
3. **Найдите предобработку.** Где вычисляются статистики нормализации — до или после разбиения? Обёрнуто ли всё в `Pipeline`?

4. **Проверьте аугментацию.** Применяется ли она к val/test?

5. **Проверьте использование теста.** Сколько раз код обращается к тестовому набору? Больше одного финального раза — красный флаг.

6. **Сверьте единицы.** Совпадает ли единица разбиения (пиксель? тайл? поле?) с единицей пространственной корреляции данных?

Полезный эмпирический тест, дополняющий чтение кода: обучите модель дважды — со случайным и с пространственным разбиением. Большой разрыв метрик между ними — количественная подпись утечки; сам по себе он не говорит, какая схема «правильная», но показывает, насколько оптимистична случайная оценка.

4.5 Чек-лист честного разбиения

- Единица разбиения — территория (полигон/поле/ячейка), не пиксель и не тайл.
- Статистики предобработки вычислены только по train (Pipeline).
- Аугментация — только в train.
- Тест заморожен до финальной оценки; решения принимаются по validation.
- Дубликаты и перекрывающиеся тайлы не пересекают границу частей.
- Разбиение зафиксировано (сохранены индексы/сиды) — результат воспроизводим.

5. Инструменты: открытый стек фреймворков

Собранный датасет попадает в один из фреймворков. Все инструменты модуля бесплатны и с открытым кодом.

scikit-learn — стандарт классического ML в Python: Random Forest, градиентный бустинг, метрики, кросс-валидация, Pipeline и групповые разбиения. Для пиксельных таблиц — инструмент первого выбора; работает на CPU, то есть в любом бесплатном Colab.

PyTorch — основной фреймворк глубокого обучения в исследовательском сообществе; на нём мы соберём CNN в [уроке 4](#). Гибкий, с огромной экосистемой; обучение свёрточных сетей комфортно при доступе к GPU (бесплатный уровень Colab периодически его предоставляет).

TensorFlow/Keras — второй большой фреймворк глубокого обучения, исторически сильный в промышленном развёртывании; в модуле упоминается для полноты — задания выполнимы на PyTorch, но конспекты Keras легко переносимы.

Hugging Face — экосистема обмена предобученными моделями и датасетами. Для ДЗ3 ценна возможность взять предобученную модель (в том числе

геопространственные foundation-модели, публикуемые открыто) и дообучить на своей задаче — это снижает потребность в размеченных данных. В модуле — обзорно; практикум обходится компактными моделями, обучаемыми с нуля.

sktime / специализированные библиотеки временных рядов — реализация MiniRocket и других методов классификации рядов; понадобится в [уроке 3](#).

Выбор фреймворка определяется представлением данных: таблица → scikit-learn, ряды → sktime, тайлы → PyTorch. Это соответствие — не догма, а разумное значение по умолчанию, экономящее время.

5.1 Воспроизводимость как инженерное требование

Датасет и эксперимент должны быть воспроизводимы — это не академическая роскошь, а условие доверия к результату (вспомните урок 1: заказчик вправе спросить, откуда данные; теперь добавьте — и как получена оценка качества). Минимальный набор мер: фиксируйте случайные сиды всех генераторов (NumPy, фреймворка, разбиения); сохраняйте версии библиотек (`pip freeze` в артефакты эксперимента); храните индексы разбиения, а не только его параметры; версионите сам датасет — хотя бы датой сборки и хешем скрипта. В ноутбуках практикума эти привычки встроены в шаблон: первая ячейка фиксирует окружение, последняя — сохраняет манифест эксперимента. Когда в [уроке 4](#) вы будете сравнивать три подхода, именно эта дисциплина позволит утверждать, что сравнение честное: одни данные, одно разбиение, одни метрики.

Региональный кейс

Ситуация: Группа студентов готовит обучающую выборку для классификации землепользования одного из районов Костанайской области — региона зернового пояса, где преобладают крупные массивы пашни, перемежающиеся пастбищами, залежами и лесополосами. Полевых данных нет; решено бутстрапировать метки укрупнённых классов из открытой карты ESA WorldCover и верифицировать их по композиту Sentinel-2.

Данные: ESA WorldCover 10 м (открытый продукт, доступен в GEE и на сайте ESA); медианный композит Sentinel-2 L2A за май–сентябрь по району (построен по методике [урока 1](#)); сетка квадратов 5×5 км для пространственного разбиения.

Задача:

1. Составьте протокол выборочной верификации меток: сколько случайных точек каждого класса проверить визуально по композиту, как фиксировать расхождения.

2. Класс WorldCover «cropland» объединяет действующую пашню и часть молодых залежей. Предложите способ отделить залежь, используя сезонную динамику NDVI (материал § 2.2–2.3).
3. Спроектируйте разбиение train/val/test по сетке 5×5 км. Почему ячейка сетки, а не пиксель, — правильная единица разбиения в этом ландшафте?

Разбор: Протокол верификации должен быть стратифицированным (фиксированное число точек на класс, а не пропорционально площади — иначе редкие классы останутся непроверенными) и слепым (проверяющий не видит метку до вынесения своего суждения). Отделение залежи от пашни строится на фенологии: у обрабатываемой пашни сезонный ход NDVI имеет характерный цикл «сев → пик → уборка» с резкими перепадами, у залежи кривая более плавная и близка к пастбищной; следовательно, в выборку нужно добавить признаки сезонной динамики, а не только композит одной даты. Пространственная единица разбиения нужна потому, что поля в зерновом поясе огромны: пиксели одного массива почти идентичны, и случайное разбиение по пикселям создаст утечку (§ 4.2). Ячейка 5×5 км гарантирует, что целые массивы с окружением уходят в одну часть выборки. Числовых «правильных ответов» здесь нет — результат верификации студенты получают и документируют сами.

Этот кейс — прямая заготовка **практикума**, где выборка собирается кодом, и **ИИ-задания**, где аналогичный пайплайн генерирует кодинг-агент, а вы его проверяете.

Закрепление и применение

Попробуйте в Colab

В ноутбуке урока (<URL будет назначен при создании репозитория ноутбуков>) соберите мини-выборку: 500 пикселей из композита Sentinel-2 с метками WorldCover, разбейте её дважды — случайно и по сетке 5×5 км — и обучите один и тот же Random Forest. Сравните точность на двух тестах. Разница, которую вы увидите, — цена пространственной утечки, измеренная вашими руками.



Границы применимости

Метки из глобальных карт пригодны только для укрупнённых классов и только после выборочной верификации; классы культур они не дают в принципе. Аугментация не компенсирует отсутствующие в выборке классы и ландшафты. Пространственное разбиение по сетке — стандартное, но не единственное решение: при сильных градиентах ландшафта (север–юг области) осмысленно блочное разбиение вдоль градиента.



Что это даёт вашему хозяйству

Понимание «откуда метки и как разбита выборка» — главный вопрос, который стоит задать любому поставщику ИИ-сервиса агромониторинга. Сервис, обученный и проверенный на «соседних пикселях», покажет красивые проценты в презентации и ошибётся на ваших полях. Умение задать этот вопрос — уже защита от некачественного продукта; версия для практиков — в [модуле ПЗ](#).



Кейс для размышления

Коллега предлагает: «Добавим в признаки классификации культур слой WorldCover — он же коррелирует с ответом!» Метки вашей выборки взяты из того же WorldCover. Найдите все дефекты этого предложения, пользуясь § 2.3 и § 4.3.

Проверь себя

Самопроверка · вариант слушателя **конспект** · вопросов: 4 · порог зачёта: 75%

1. Пиксельная таблица, тайлы и временные ряды — три представления ДЗЗ-данных. Какое из них напрямую кодирует фенологию культуры?

- ☐ Пиксельная таблица по композиту одной даты
- ☐ Временные ряды NDVI/EVI за сезон
- ☐ Тайлы 256×256 с одного снимка
- ☐ Все три представления кодируют фенологию одинаково

2. Аугментацию (повороты, отражения тайлов) применяют:

- ☐ Только к тестовой части — для стресс-теста модели
- ☐ Ко всей выборке до разбиения — так больше данных

- ☐ Только к обучающей части выборки
- ☐ К валидационной и тестовой частям в равной мере

3. Какая последовательность действий с нормализацией признаков корректна?

- ☐ Нормализация не влияет на честность оценки, порядок не важен
- ☐ Нормализовать каждую часть её собственными статистиками
- ☐ Разбить выборку → вычислить среднее и дисперсию по train → применить их к val и test
- ☐ Вычислить среднее и дисперсию по всей выборке → разбить → нормализовать каждую часть

4. В чём механизм пространственной утечки данных при случайном разбиении пиксельной выборки?

- ☐ Случайное разбиение уменьшает размер обучающей выборки
- ☐ Соседние почти одинаковые пиксели одного поля попадают и в train, и в test — тест перестаёт быть независимым
- ☐ Случайное разбиение делает классы несбалансированными
- ☐ Пиксели теряют геопривязку при перемешивании

Проверить

Контрольные вопросы

1. Назовите три источника меток и по одному ограничению каждого. (*Bloom: знать*)
2. Объясните коллеге-агроному без математики, почему «модель проверили на соседних пикселях» — это не проверка. (*Bloom: понимать*)
3. Спроектируйте схему разбиения выборки для классификации землепользования вашего района СКО: единица группировки, доли частей, что фиксируете для воспроизводимости. (*Bloom: применять*)

Что дальше?

Датасет собран и честно разбит — пора обучать модели. [Урок 3 «Обучаем интерпретируемые модели»](#) начинается с Random Forest и градиентного бустинга на пиксельной таблице и продолжает MiniRocket на рядах NDVI. Затем [урок 4](#) добавит

CNN и сведёт все три подхода в честное сравнение. Связанные материалы: [политика датасетов платформы](#), [модуль П4 — Python и Jupyter для специалистов](#).

Обучаем интерпретируемые модели: Random Forest, Gradient Boosting и MiniRocket на рядах NDVI

🕒 **Трудозатраты:** ~23 мин чтения + ~25 мин практики Модуль **А3: ИИ и машинное обучение в агроэкологическом мониторинге**, урок 3 из 4. Академический уровень. Проект UNDP-KAZ FOLUR. Компоненты FOLUR: **1, 2, 3**.

Цели лекции и место в модуле

Датасет собран и честно разбит (**урок 2**) — начинаем обучать модели. Первыми идут не нейросети, а классические методы, и это осознанный порядок: в реальных проектах агромониторинга Random Forest и градиентный бустинг решают львиную долю задач классификации землепользования — при малых данных, без GPU, с интерпретируемым результатом. Начинать с них — не уступка простоте, а профессиональная стратегия: простая работающая модель одновременно даёт результат и служит честной планкой, ниже которой сложные методы не имеют оправдания. Отдельная линия этой лекции — классификация культур по фенологии через MiniRocket: метод, специально созданный для быстрой и точной работы с временными рядами. К концу урока у вас будут два из трёх подходов, которые **урок 4** сведёт в общее сравнение.

После изучения лекции слушатель сможет:

1. **[Bloom: знать]** описывать устройство решающего дерева, случайного леса (Random Forest), градиентного бустинга и преобразования MiniRocket для временных рядов.
2. **[Bloom: понимать]** объяснять, почему ансамбли деревьев устойчивы к переобучению и как читать важность признаков.
3. **[Bloom: применять]** обучать Random Forest и градиентный бустинг на пиксельной таблице Sentinel-2 и MiniRocket на рядах NDVI по данным Северного Казахстана.
4. **[Bloom: анализировать]** сравнивать классические модели по качеству и стоимости и обосновывать, когда какой метод предпочтителен.

Границы лекции. Внутри: решающие деревья, Random Forest, градиентный бустинг, MiniRocket, важность признаков, интерпретируемость. За рамками: свёрточные

1. Решающее дерево — атом интерпретируемости

Прежде чем говорить о лесах, поймём одно дерево. Решающее дерево классифицирует объект серией вопросов «да/нет» к его признакам: «NDVI в июле > 0,6? — да → влево; отражение в SWIR > порога? — нет → вправо» и так до листа, где выносится класс. Эта логика знакома каждому агроному, который в поле рассуждает похоже: «всходы дружные? почва не засолена? тогда это озимые» — дерево лишь автоматизирует и масштабирует такое рассуждение на миллионы пикселей. Обучение дерева — это подбор вопросов (признак и порог), максимально «очищающих» подвыборку в каждом узле: после хорошего вопроса потомки однороднее по классам, чем родитель (мера однородности — индекс Джини или энтропия). Алгоритм жадно перебирает возможные разбиения и выбирает то, что сильнее всего снижает «беспорядок», и так рекурсивно, пока узлы не станут достаточно чистыми или не сработает ограничение глубины.

Достоинство дерева — прозрачность: путь от корня к листу читается как понятное правило, и агроному можно показать, почему пиксель отнесён к пашне. Беда одного дерева — неустойчивость: глубокое дерево идеально запоминает обучающую выборку (включая её шум) и плохо обобщается — классическое переобучение. Мелкое дерево устойчивее, но слишком грубо. Из этого противоречия и рождается идея ансамбля.

Полезно заранее развести два понятия, которые часто путают. **Переобучение** — модель выучила случайности конкретной выборки и потому хороша на обучении, но слаба на новых данных (высокая дисперсия). **Недообучение** — модель слишком проста, чтобы уловить закономерность, и слаба везде (высокое смещение). Глубокое дерево склонно к первому, мелкое — ко второму. Ансамбли деревьев — способ получить низкое смещение (деревья гибкие) при управляемой дисперсии (усреднение гасит случайные ошибки). Эта пара «смещение–дисперсия» — сквозная линза всего машинного обучения, и мы вернёмся к ней, обсуждая нейросети в [уроке 4](#).




Рис. 1. Упрощённое решающее дерево классификации землепользования: серия вопросов к спектральным признакам и NDVI ведёт от корня к классу-листу. Пороги условны и иллюстрируют логику, а не готовое правило. Alt: древовидная схема, где узлы задают вопросы о NDVI и спектральных каналах, а листья присваивают классы землепользования.

Подробнее о том, откуда берутся признаки NDVI и спектральных каналов, — в [уроке 1](#) и [уроке 2](#).

2. Random Forest — мудрость несогласного леса

2.1 Идея ансамбля

Random Forest («случайный лес») строит не одно дерево, а сотни, и усредняет их голоса. Два источника разнообразия делают деревья по-разному ошибающимися. Первый — **бэггинг**: каждое дерево обучается на случайной подвыборке данных (с возвращением). Второй — **случайные признаки**: в каждом узле дерево выбирает лучший вопрос не из всех признаков, а из случайного их подмножества. В результате отдельные деревья остаются «слабыми» и переобученными по-своему, но их *ошибки некоррелированы* и при усреднении гасятся — лес обобщает заметно лучше любого своего дерева. Это и есть «мудрость толпы»: много независимо ошибающихся экспертов вместе точнее одного. В терминах § 1: усреднение снижает дисперсию ансамбля, почти не увеличивая смещение, — потому и переобучение отступает.

2.2 Почему RF — рабочая лошадка ДЗЗ

Random Forest доминирует в задачах классификации землепользования по нескольким практическим причинам. Он устойчив к переобучению «из коробки» — добавление деревьев не ухудшает обобщение. Он почти не требует настройки — работает разумно на значениях по умолчанию. Ему безразличен масштаб признаков — не нужна нормализация. Он справляется с малыми выборками (сотни примеров на класс) и не требует GPU. Наконец, он даёт **важность признаков** — оценку вклада каждого канала/индекса в решения, что бесценно для интерпретации и для отбрасывания бесполезных признаков.

Ещё одно недооценённое достоинство — RF выдаёт не только класс, но и **оценку уверенности**: долю деревьев, проголосовавших за победивший класс. Пиксели, где голоса разделились почти поровну, — это зоны неуверенности модели, и карта уверенности не менее полезна заказчику, чем карта классов: она показывает, где результату можно доверять, а где нужна полевая проверка. Это прямое продолжение инварианта «человек верифицирует»: модель сама подсказывает, куда направить верификацию. Профессиональная привычка — сдавать вместе с картой классификации карту уверенности, честно очерчивающую границы надёжности продукта.

Минимальный код на scikit-learn лаконичен:

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GroupKFold # пространственные группы!
(урок 2)

clf = RandomForestClassifier(n_estimators=300, oob_score=True,
                             random_state=42)
clf.fit(X_train, y_train)
importances = clf.feature_importances_ # вклад признаков
```

Обратите внимание на `oob_score`: «out-of-bag» оценка — бесплатный побочный продукт бэггинга. Каждое дерево не видело часть данных (те, что не попали в его подвыборку), и на них можно оценить лес без отдельного валидационного набора. Это удобная быстрая оценка — но помните урок 2: при пространственной автокорреляции ООВ, как и случайное разбиение, оптимистичен; финальную оценку даёт пространственно отделённый тест.

Гиперпараметров у Random Forest немного, и почти все имеют разумные значения по умолчанию. `n_estimators` (число деревьев) — больше почти всегда не вредит качеству, лишь замедляет; типично несколько сотен. `max_features` (сколько признаков рассматривать в узле) управляет разнообразием деревьев — уменьшение усиливает декорреляцию. `max_depth` и `min_samples_leaf` ограничивают глубину и тем самым переобучение отдельных деревьев. На практике настройка RF редко даёт большой выигрыш — в этом его прелесть: он работает «из коробки», освобождая время на то, что важнее, — качество данных и честность разбиения. Если хочется

настроить, делайте это через групповую (пространственную) кросс-валидацию из [урока 2](#), иначе подбор параметров сам станет каналом утечки.

2.3 Чтение важности признаков — с осторожностью

Важность признаков отвечает на вопрос «на какие каналы лес опирается сильнее». Если верх списка занимают июльский NDVI и красный край — это согласуется с агрономическим смыслом (пик вегетации разделяет культуры), и доверие к модели растёт. Но у стандартной (based на примесях) важности есть известные ловушки: она завышает вклад признаков с большим числом уникальных значений и «размазывает» важность между коррелированными признаками (а спектральные каналы сильно коррелированы). Поэтому для ответственных выводов применяют пермутационную важность (насколько падает качество при перемешивании признака) — она честнее и вычисляется на отложенных данных. Интерпретация важности — не украшение отчёта, а инструмент верификации: признак, «важный» вопреки всякому физическому смыслу, часто оказывается каналом утечки данных из [урока 2](#).

2.4 Где Random Forest пасует

Честная карта метода включает и его слабости. RF плохо экстраполирует: он предсказывает классы, комбинируя *виденные* значения, и на данных из принципиально новых условий (другой сенсор, другой год с аномальной погодой, другой регион) его надёжность падает — это общая беда моделей, обученных на ограниченной выборке, и лекарство одно: репрезентативность данных ([урок 2](#)). Он не видит пространственный контекст, поэтому «солит» карту — соседние пиксели могут получить разные классы там, где человек видит единое поле (частично лечится постобработкой: сглаживанием, объединением по контурам полей). И он, при всей интерпретируемости отдельного дерева, как ансамбль из сотен деревьев уже не читается «одним правилом» — приходится опираться на важность признаков и карты уверенности. Знать эти границы важно не меньше, чем достоинства: именно на них строится обоснованный переход к другим методам.

3. Градиентный бустинг — точность ценой аккуратности

3.1 Другая идея ансамбля

Если Random Forest строит деревья *независимо и параллельно*, то градиентный бустинг строит их *последовательно*: каждое следующее дерево учится исправлять ошибки уже построенного ансамбля. Формально каждое дерево аппроксимирует градиент функции потерь — отсюда название. Образно: RF — это комитет независимых экспертов, голосующих одновременно, а бустинг — цепочка учеников, где каждый

следующий специализируется на том, что не осилил предыдущий. Результат — обычно более точная модель, чем RF, при меньшем числе деревьев. Современные реализации (`HistGradientBoosting` в `scikit-learn`, а также библиотеки `XGBoost`, `LightGBM`, `CatBoost` — все открытые) быстры и хорошо масштабируются.

3.2 Цена точности

За точность бустинг берёт плату вниманием. Он чувствителен к переобучению: слишком много деревьев или слишком большая скорость обучения — и модель запоминает шум. Поэтому у него больше гиперпараметров, требующих настройки (скорость обучения, глубина деревьев, число итераций, регуляризация), и почти обязателен механизм ранней остановки по валидации. Практическое правило модуля: **начните с `Random Forest` как надёжной базовой линии**; переходите к бустингу, когда нужно выжать последние проценты качества и есть время на аккуратную настройку с честной (пространственной) валидацией. Для многих задач картирования землепользования разница между аккуратно настроенным бустингом и RF по умолчанию невелика — а риск незаметно переобучить бустинг реален.

Полезно знать и различия популярных реализаций бустинга, все они открытые и бесплатные. **XGBoost** — исторически задавший стандарт, надёжный и хорошо документированный. **LightGBM** — оптимизирован под скорость и большие таблицы (гистограммный рост деревьев по листьям). **CatBoost** — силён при наличии категориальных признаков и меньше требует ручной настройки.

`HistGradientBoosting` в самом `scikit-learn` покрывает большинство учебных задач без установки внешних библиотек. Для задач модуля различия между ними второстепенны: выбирайте то, что уже установлено, и тратьте усилия на данные и валидацию, а не на «гонку фреймворков». Единый принцип для всех — обязательная ранняя остановка по честной валидации и сдержанность в числе итераций.

3.3 Общая сила деревьев и общий предел

И RF, и бустинг работают с объектом как с *таблицей чисел* — им безразличен пространственный и временной порядок. Это одновременно сила (простота, любые признаки в одной таблице) и предел: подав в таблицу значения NDVI за разные даты как отдельные столбцы, дерево не «знает», что столбцы упорядочены во времени, и не использует форму кривой напрямую. Для укрупнённых классов землепользования этого предела часто не замечаешь. Но для тонкой классификации культур, где вся информация — в *форме* сезонной кривой, нужен метод, который эту форму видит. Так мы приходим к `MiniRocket`.

3.4 Инженерия признаков — там, где деревья особенно сильны

Поскольку деревьям всё равно, что стоит в столбцах таблицы, они дают простор для **инженерии признаков** — осмысленного конструирования входов из сырых данных. Вместо того чтобы подавать «сырые» значения каналов за каждую дату, аналитик может добавить производные, кодирующие агрономический смысл: амплитуду сезонного хода NDVI (разность пика и минимума), дату достижения пика, площадь под кривой NDVI за сезон (интегральная продуктивность), спектральные индексы влажности и почвы, статистики рельефа (уклон, экспозиция из ASTER GDEM, [урок 1](#)). Такие признаки часто поднимают качество классических моделей заметнее, чем смена алгоритма.

В этом — важное методологическое отличие классического ML от глубокого обучения. Деревьям аналитик *приносит* готовые осмысленные признаки; свёрточные сети [урока 4](#) учатся извлекать признаки *сами* из сырых снимков. Оба пути легитимны; выбор между «человек конструирует признаки» и «сеть их выучивает» — одно из ключевых архитектурных решений, к которому мы вернёмся в финальном сравнении. Пока запомним практический вывод: при работе с деревьями время, вложенное в продуманные признаки, окупается лучше времени, вложенного в тонкую настройку гиперпараметров.

4. MiniRocket — фенология как признак

4.1 Задача классификации временных рядов

Вспомним [урок 1](#): яровая пшеница, ячмень, пар и залежь на отдельном снимке почти неразличимы, но их сезонные кривые NDVI различаются формой — сроками сева, датой и высотой пика, скоростью созревания. Задача «по кривой NDVI за сезон определить культуру» — это классификация временных рядов, отдельная область ML со своими методами.

Почему нельзя просто скормить те же даты в Random Forest как столбцы? Формально можно, и иногда это даже работает — но дерево видит столбцы как независимые признаки и не использует главное: что «NDVI 10 июня» и «NDVI 20 июня» — соседние точки одного процесса, а не два разных измерения. Если поле снято в чуть иные даты или сезон сдвинулся из-за поздней весны, «столбцовая» модель теряется, потому что для неё сдвиг фенологии на неделю — это совсем другие значения в тех же столбцах. Методы временных рядов, напротив, работают с *формой* сигнала и устойчивее к таким сдвигам. Это и есть содержательная причина выделять фенологию в отдельный инструмент, а не решать её деревьями «в лоб».

4.2 Что делает MiniRocket

MiniRocket (Minimally RandOm Convolutional KErnel Transform) преобразует каждый временной ряд в вектор признаков, прогоняя по нему большой набор **фиксированных**

свёрточных ядер и вычисляя для каждого простую статистику — долю положительных значений отклика (PPV). Ключевое слово — «фиксированных»: ядра не обучаются (в отличие от CNN), они заданы почти детерминированно, поэтому преобразование исключительно быстрое. Полученные признаки подаются в простой линейный классификатор (логистическая регрессия/линейный SVM), который обучается за секунды.

Интуиция за этим такова: каждое свёрточное ядро — маленький «детектор формы», реагирующий на определённый паттерн в ряду (резкий подъём, плоское плато, спад). Прогнав тысячи разных ядер, мы описываем кривую NDVI набором ответов на вопрос «насколько в ней выражен вот такой паттерн». Доля положительных откликов (PPV) оказывается на удивление информативной сводкой формы. Гениальность MiniRocket в том, что эти детекторы не нужно обучать под задачу — достаточно большого фиксированного набора, и линейный классификатор сам разберётся, какие ответы для каких культур характерны. Так метод обходит главную стоимость нейросетей — долгое обучение сложных весов — сохраняя способность видеть форму сигнала.

Практический профиль метода: **очень быстро**, требует умеренных данных (сотни рядов на класс), не нуждается в GPU, при этом по точности на задачах классификации рядов конкурентоспособен с гораздо более тяжёлыми подходами. Для агромониторинга это почти идеальная ниша: многолетние ряды NDVI/EVI из открытых архивов ([урок 1](#)) есть в изобилии, а MiniRocket превращает их в классификатор культур без GPU и долгого обучения. Реализация доступна в открытой библиотеке `sktime` (и родственниках).

Стоит отметить, что MiniRocket — представитель целого семейства «rocket»-методов (ROCKET, MiniRocket, MultiRocket), возникшего как быстрая альтернатива глубоким сетям для рядов. Существуют и другие подходы к классификации фенологии: расстояние динамической трансформации времени (DTW) с ближайшими соседями, специализированные рекуррентные и трансформерные сети, а также «ручные» фенологические признаки, поданные в обычный Random Forest (§ 3.4). MiniRocket выбран в модуле как метод с лучшим на сегодня балансом «скорость / точность / скромность к ресурсам» — но, как всегда, простой базовый вариант (фенологические признаки + RF) стоит попробовать первым: если он решает задачу, усложнение не нужно.

```
from sktime.transformations.panel.rocket import MiniRocket
from sklearn.linear_model import RidgeClassifierCV

mr = MiniRocket()                                # фиксированные ядра
X_feat = mr.fit_transform(X_series_train)         # ряды NDVI → признаки
clf = RidgeClassifierCV().fit(X_feat, y_train)
```

4.3 Ограничения и честность

MiniRocket не всесилен. Он требует *выровненных* рядов — одинаковой длины и сопоставимых дат; пропуски (облачные даты!) нужно заполнять или интерполировать заранее, а нерегулярность съёмки — учитывать. Он работает с рядом как с одномерным сигналом: многоканальные ряды обрабатываются, но межканальные зависимости он ловит слабее специализированных методов. И, как любой метод, он даёт *оценку* качества, которая честна лишь при пространственно-корректном разбиении рядов (поле целиком — в одну часть выборки). Все конкретные значения точности вы получите в [практикуме](#) на своих данных — лекция принципиально не приводит «эталонных» цифр, потому что они зависят от района, набора культур и качества рядов.

4.4 Подготовка рядов NDVI: практические шаги

Прежде чем ряд попадёт в MiniRocket, он проходит подготовку, качество которой определяет результат сильнее выбора самого метода. Первый шаг — **очистка от облаков**: значения NDVI в облачные даты недостоверны и должны быть удалены по маске SCL ([урок 1](#)), а не оставлены как есть. Второй — **приведение к регулярной сетке дат**: реальные сцены приходят нерегулярно, поэтому ряд интерполируют на равномерную временную решётку (например, декадную), чтобы все поля имели сопоставимые по датам ряды. Третий — **сглаживание**: лёгкий фильтр (скользящее среднее, Савицкого–Голея) убирает остаточный шум, не разрушая форму кривой. Четвёртый — **выравнивание длины**: все ряды должны покрывать одно временное окно сезона.

Эти шаги — не бюрократия, а содержательные решения. Слишком агрессивная интерполяция может «придумать» вегетацию там, где были только облака; слишком сильное сглаживание сотрёт различия между быстро и медленно созревающими культурами. Здесь снова работает инвариант платформы: автоматический конвейер подготовки рядов ускоряет работу, но аналитик обязан выборочно посмотреть на несколько собранных кривых глазами и убедиться, что они физически правдоподобны — пик приходится на середину лета, а не на апрель. Кривая NDVI с пиком в неправильный сезон — сигнал ошибки в подготовке, а не открытие.

5. Когда что: карта выбора классических моделей

Сведём практические ориентиры в таблицу — она пригодится и при выборе метода, и при защите выбора перед заказчиком.

Метод	Представление	Данные	Ресурсы	Сильная сторона	Комментарий
Random Forest	пиксельная таблица	сотни/класс	CPU, минуты	устойчивость, важность признаков, уверенность	ба кл зе
Градиентный бустинг	пиксельная таблица	сотни/класс	CPU, минуты	максимум точности на таблицах	вь ес на
MiniRocket	ряды NDVI/EVI	сотни рядов/класс	CPU, секунды–минуты	видит форму сезонной кривой	кл ку. фе

Все три — быстры, скромны к ресурсам и не требуют GPU; все три уступают CNN там, где решает пространственный контекст высокого разрешения — но об этом [урок 4](#). Заметьте, что таблица не содержит столбца «точность»: её значение зависит от данных и определяется экспериментом, а не свойствами метода — вписать туда числа заранее было бы научной нечестностью.

Важнее конкретного выбора — принцип: **начинать с простого**. Простая, интерпретируемая, быстро обучаемая модель — это и рабочее решение для многих задач, и честная база сравнения: если сложная нейросеть не превосходит Random Forest, её сложность не оправдана. Этот принцип экономии — профессиональная норма, а не признак неамбициозности.

5.1 Стоимость владения, а не только точность

Инженерное решение о выборе модели учитывает не одну точность. Есть **стоимость обучения** (RF и MiniRocket — минуты на CPU; CNN — часы и GPU), **стоимость инференса** (насколько дорого применять модель к новым снимкам — важно, если мониторинг еженедельный), **стоимость сопровождения** (кто и как переобучит модель через год, когда изменится набор культур), **объяснимость** (сможете ли вы обосновать результат перед акиматом или аудитором). Для проекта FOLUR, ориентированного на устойчивость решений после завершения (нулевая инфраструктурная зависимость платформы), эти оси часто перевешивают доли процента точности. Модель, которую хозяйство сможет переобучать само в бесплатном Colab, полезнее чуть более точной модели, требующей GPU-сервера и штатного инженера.

Именно поэтому классические методы этого урока — не «разминка перед настоящими нейросетями», а полноценные производственные инструменты. В следующем уроке мы добавим CNN не чтобы заменить их, а чтобы очертить границу, за которой пространственный контекст высокого разрешения оправдывает дополнительную сложность.

Региональный кейс

Ситуация: Агроном хозяйства в Акмолинской области хочет автоматически разделить поля севооборота на «яровая пшеница», «пар» и «многолетние травы» по данным прошедшего сезона, не выезжая на каждое поле. У него есть журнал севооборота за несколько лет (метки по полям) и доступ к открытым архивам Sentinel-2.

Данные: ряды NDVI по полям за сезон май–сентябрь (Sentinel-2 L2A, GEE, методика [урока 1](#)); метки культур из журнала севооборота хозяйства (метки уровня поля, [урок 2](#)); границы полей — оцифровка/OSM.

Задача:

1. Какое представление данных выбрать — пиксельную таблицу для Random Forest или ряды для MiniRocket — и почему именно для различения культур?
2. Как разбить выборку, чтобы оценка была честной, если объект — поле, а меток по несколько десятков полей на класс?
3. Проверив важность признаков RF (если выбран RF), какой период сезона вы ожидаете увидеть наверху и как это согласуется с фенологией культур?

Разбор: Для различения культур предпочтителен ряд + MiniRocket: информация о культуре заключена в *форме* сезонной кривой (сроки и высота пика NDVI, скорость созревания), а не в значениях отдельной даты — именно это MiniRocket и кодирует, тогда как таблица подаёт даты деревьям как несвязанные столбцы (§ 3.3, § 4.1). Разбиение — строго по полям (все пиксели/ряды одного поля в одной части выборки), при малом числе полей — групповая кросс-валидация (`GroupKFold` по полю), чтобы не терять данные; тест — из полей, не участвовавших в обучении. Если применяется RF, наверху важности ожидаемо окажутся признаки середины–конца лета: именно тогда пшеница на пике, а пар остаётся открытой почвой — период максимального контраста классов. Конкретные метрики агроном получает сам; лекция не называет чисел, которых не существует до эксперимента.

Кейс полностью реализуется в [практикуме](#), где RF, MiniRocket и CNN обучаются на одном районе и сравниваются.

Закрепление и применение



Попробуйте в Colab

В ноутбуке урока (<URL будет назначен при создании репозитория ноутбуков>) обучите Random Forest на пиксельной таблице и MiniRocket на рядах NDVI из одного района. Сравните: время обучения, качество на пространственном тесте, и — для RF — топ-5 важности признаков. Совпал ли топ важности с вашими ожиданиями по фенологии?



Границы применимости

Классические модели не видят пространственный контекст (текстуру, форму границ) — для задач высокого разрешения (детекция сорняков на ортофото БПЛА) нужна CNN из урока 4. MiniRocket требует выровненных рядов без больших пропусков — облачные даты придётся интерполировать. Стандартная важность признаков RF смещена в пользу коррелированных и «богатых значениями» признаков — для выводов используйте пермутационную важность.



Что это даёт вашему хозяйству

Random Forest и MiniRocket — это ML, который реально работает без дорогого «железа»: обучается в бесплатном Colab на CPU за минуты и даёт объяснимый результат, который не стыдно показать агроному. Именно эти методы стоят за многими сервисами NDVI-мониторинга; версия без программирования — [модуль П3](#), первый Python-скрипт — [модуль П4](#).



Кейс для размышления

Коллега обучил градиентный бустинг, получил на тесте качество заметно выше вашего Random Forest и предлагает внедрять его. Какие три вопроса вы зададите, прежде чем согласиться (подсказки: разбиение из урока 2, ранняя остановка из § 3.2, важность признаков из § 2.3)?

Проверь себя

Самопроверка · вариант слушателя [конспект](#) · вопросов: 4 · порог зачёта: 75%

1. Почему для различения яровой пшеницы, пара и залежи предпочтительнее MiniRocket на рядах NDVI, а не Random Forest на таблице дат?

- ☐ Информация о культуре — в форме сезонной кривой; MiniRocket видит форму ряда, а дерево трактует даты как несвязанные столбцы
- ☐ Random Forest не работает с индексом NDVI
- ☐ MiniRocket требует GPU и потому мощнее
- ☐ MiniRocket точнее на любых задачах, чем деревья

2. Признак с высокой важностью в RF противоречит агрономическому смыслу. О чём это чаще всего сигнализирует?

- ☐ Это нормально и не требует внимания
- ☐ О необходимости добавить больше деревьев
- ☐ О возможной утечке данных — признак несёт информацию о метке нефизическим путём
- ☐ О том, что модель обучилась особенно хорошо

3. Чем градиентный бустинг принципиально отличается от Random Forest по способу построения деревьев?

- ☐ Строит деревья последовательно: каждое исправляет ошибки предыдущего ансамбля
- ☐ Строит деревья независимо и параллельно, затем усредняет
- ☐ Использует только одно дерево, но очень глубокое
- ☐ Не использует деревья, а строит линейную модель

4. За счёт чего Random Forest обобщает лучше, чем отдельное глубокое дерево?

- ☐ Нормализует признаки перед обучением
- ☐ Использует GPU для ускорения обучения
- ☐ Строит одно очень глубокое дерево, точно запоминающее выборку
- ☐ Усредняет голоса многих деревьев, чьи ошибки некоррелированы благодаря бэггингу и случайным признакам

Проверить

1. Опишите, чем бэггинг отличается от бустинга. (*Bloom: знать*)
2. Объясните, почему стандартную важность признаков RF нельзя читать буквально. (*Bloom: понимать*)
3. Для задачи «пашня / не пашня» по вашему району СКО обоснуйте выбор между Random Forest и градиентным бустингом. (*Bloom: применять*)

Что дальше?

Урок 4 «Сегментируем снимки и выбираем архитектуру» добавит третий подход — свёрточные нейросети (U-Net, ResNet), разберёт метрики (F1, IoU, каппа Коэна) и матрицу ошибок и, наконец, честно сравнит все три подхода на общем материале, замкнув логику модуля. Связанные материалы: [модуль П4 — Python и Jupyter](#), [практикум модуля](#).

Сегментируем снимки и выбираем архитектуру: CNN, метрики и честное сравнение трёх подходов

🕒 **Трудозатраты:** ~24 мин чтения + ~25 мин практики Модуль **А3: ИИ и машинное обучение в агроэкологическом мониторинге**, урок 4 из 4. Академический уровень. Проект UNDP-KAZ FOLUR. Компоненты FOLUR: **1, 2, 3**.

Цели лекции и место в модуле

Два подхода уже в руках: интерпретируемые деревья на таблице и MiniRocket на рядах (**урок 3**). Третий — свёрточные нейросети (CNN) — открывает то, чего не видят табличные методы: пространственный контекст, текстуру, форму. Но CNN дороги данными и вычислениями, и подключать их следует осознанно. Эта заключительная лекция модуля разбирает CNN (ResNet для классификации, U-Net для сегментации), учит честно измерять качество (F1, IoU, каппа Коэна, матрица ошибок) и, наконец, сводит все три подхода в обоснованное сравнение — тот самый навык «выбрать архитектуру под задачу», ради которого построен весь модуль. Это кульминация логики «от инструмента к применению»: инструменты собраны, и теперь главным становится инженерное суждение о том, какой из них уместен и как честно доказать, что он работает.

После изучения лекции слушатель сможет:

1. **[Bloom: знать]** описывать устройство свёрточной сети, различие классификации (ResNet) и семантической сегментации (U-Net) и определения метрик F1, IoU, каппа Коэна.
2. **[Bloom: понимать]** объяснять, почему общая точность (ассурасу) обманчива при дисбалансе классов и как матрица ошибок раскрывает поведение модели.
3. **[Bloom: применять]** обучать компактную CNN на тайлах Sentinel-2 и вычислять корректный набор метрик по данным Северного Казахстана.
4. **[Bloom: анализировать]** сравнивать RF, MiniRocket и CNN по качеству, стоимости и применимости и аргументированно выбирать архитектуру под конкретную задачу.

Границы лекции. Внутри: свёртки, ResNet, U-Net, перенос обучения, метрики, матрица ошибок, анализ ошибок, итоговое сравнение подходов. За рамками:

классические модели — [урок 3](#); подготовка тайлов и разбиение — [урок 2](#); применение CNN к ортофото БПЛА (детекция сорняков) обзорно — практика в [модуле A1](#).

1. Свёрточная сеть: как машина «видит» текстуру

Табличные методы урока 3 видят пиксель как набор чисел вне контекста. Человек же, глядя на снимок, опознаёт поле не по одному пикселю, а по *форме контура, текстуре поверхности, соседству объектов*. Свёрточная нейросеть (Convolutional Neural Network, CNN) формализует именно это зрение. Разница принципиальна: там, где Random Forest спросит «какое значение NDVI в этом пикселе», CNN спросит «на что похож этот участок изображения целиком» — и это открывает доступ к признакам, которых в отдельном пикселе просто нет.

Базовая операция — **свёртка**: небольшое окно-фильтр (например, 3×3) скользит по изображению и в каждой позиции считает взвешенную сумму пикселей под собой. По сути это тот же принцип, что и «скользящее окно» в обработке изображений, известный из ГИС ([модуль A2](#)): фокусный анализ раstra, где значение пикселя пересчитывается по его соседям. Разница в том, что веса окна CNN не задаёт человек — их подбирает обучение. Разные фильтры реагируют на разные локальные паттерны — границу, пятно, полосу. Один фильтр может «загораться» на резких перепадах яркости (границы полей), другой — на регулярной текстуре (рядки посева), третий — на однородных пятнах (водная гладь). Ключевое отличие от MiniRocket: здесь фильтры **обучаются** — сеть сама подбирает, какие паттерны выделять под задачу, а не берёт их из фиксированного набора. Складывая свёрточные слои в глубину и чередуя их с операциями снижения разрешения (пулинг), сеть строит иерархию признаков: ранние слои ловят края и текстуры, глубокие — сложные объекты (контур поля, структуру лесополосы). Эта выученная иерархия — то, что отличает глубокое обучение от классического: признаки не конструируются человеком (§ 3.4 [урока 3](#)), а извлекаются сетью из сырых снимков.




Рис. 1. Свёрточная сеть извлекает иерархию признаков из тайла, а «голова» решает задачу: классификация присваивает класс всему тайлу (ResNet), сегментация — каждому

пикселю (U-Net). Alt: блок-схема, где входной тайл проходит через свёрточные блоки к двум типам выходов — классификации всего тайла и попиксельной сегментации.

За выразительность приходится платить. CNN **прожорливы к данным** (тысячи размеченных тайлов, [урок 2](#)), **требуют GPU** для разумного времени обучения, **склонны к переобучению** при малых выборках и **непрозрачны** — объяснить решение сети труднее, чем путь по дереву. Эти издержки и определяют, когда CNN оправданы.

1.1 Как учится сеть: потери, градиент, эпохи

Чтобы осознанно применять CNN и читать чужой код обучения, полезно понимать сам процесс. Сеть учится, минимизируя **функцию потерь** — числовую меру расхождения между её предсказаниями и эталонными метками (для классификации это обычно перекрёстная энтропия). Алгоритм обратного распространения вычисляет, как менять каждый вес, чтобы потери уменьшились (это и есть градиент), а оптимизатор (SGD, Adam) делает маленький шаг в нужную сторону. Один проход по всей обучающей выборке называют **эпохой**; сеть учится многими эпохами, постепенно снижая потери.

Здесь и подстерегает переобучение: если учить слишком долго, потери на обучении продолжают падать, а на валидации — начинают расти, потому что сеть запоминает шум. Отсюда обязательные инструменты: слежение за кривыми потерь train/val, **ранняя остановка** (прекратить, когда валидация перестала улучшаться), регуляризация (dropout, штраф на веса) и аугментация ([урок 2](#)). Всё это — та же борьба смещения и дисперсии, что и у деревьев ([урок 3, § 1](#)), только у сетей рычагов управления больше, а цена ошибки выше. Расхождение кривых потерь train и val — первый график, на который смотрит инженер: он честно показывает, учится модель или заучивает.

Подробнее о нарезке тайлов, аугментации и балансировке классов для CNN — в [уроке 2](#).

2. Две задачи — две архитектуры

2.1 ResNet: классификация тайла

Когда нужно присвоить *один класс* целому *фрагменту* («этот тайл — преимущественно пашня»), применяют классифицирующие CNN. **ResNet** (Residual Network) — базовая архитектура этого класса; её изобретение — «остаточные связи» (skip-соединения), позволяющие обучать очень глубокие сети без деградации градиента. До ResNet попытки строить очень глубокие сети упирались в парадокс: добавление слоёв *ухудшало* результат, потому что градиент, пробираясь через десятки слоёв назад, затухал. Остаточная связь пропускает сигнал «в обход» блока, давая градиенту

короткий путь, — и внезапно стало возможным обучать сети из сотен слоёв. Эта идея настолько удачна, что skip-соединения теперь есть почти в каждой современной архитектуре, включая U-Net. Для агромониторинга классификация тайлов уместна, когда интересуется состав территории по крупным ячейкам, а не точная граница каждого поля.

2.2 U-Net: семантическая сегментация

Чаще в картировании землепользования нужен *класс для каждого пикселя* — тогда результат прямо ложится в карту. Это задача семантической сегментации, и её эталонная архитектура — **U-Net**. Её форма буквы «U» — это сжимающий путь (свёртки + пулинг, извлечение контекста) и расширяющий путь (постепенное восстановление разрешения), соединённые «мостиками» (skip-соединениями), которые возвращают в выход точные границы, теряемые при сжатии. U-Net, придуманная для медицинских изображений, стала рабочим стандартом сегментации ДЗЗ: она аккуратно проводит границы полей и требует умеренных данных по меркам глубокого обучения.

Интуиция за U-образной формой такова. Чтобы понять, что изображено (пашня или вода), сети нужен широкий контекст — она сжимает изображение, жертвуя деталями ради «общей картины». Но чтобы провести границу *точно по пикселю*, нужны как раз детали, потерянные при сжатии. Skip-соединения решают эту дилемму, прокидывая детали с ранних слоёв прямо в расширяющий путь: глубина даёт «что», мостики возвращают «где». Именно поэтому U-Net одновременно и понимает содержание, и аккуратно очерчивает границы — сочетание, критичное для карт, где неверно проведённая межа поля искажает площади и, в конечном счёте, расчёты субсидий или деградации земель.

2.3 CNN на данных БПЛА высокого разрешения

Настоящая сила CNN раскрывается на снимках высокого разрешения, где решает текстура и форма отдельных объектов. На ортофотопланах БПЛА (сантиметры на пиксель, **модуль A1**) CNN решают задачи, недоступные спутнику 10 м: детекция очагов сорняков, подсчёт всходов, выявление поражённых участков. В нашем модуле практикум работает на Sentinel-2 (доступно каждому, без БПЛА), но помните: чем выше разрешение и важнее форма, тем сильнее перевес CNN над табличными методами.

Обратная сторона того же правила: на грубом разрешении, где объект укладывается в один-два пикселя, пространственный контекст беден, и преимущество CNN тает — табличный метод по спектру работает не хуже, а стоит несравнимо дешевле. Поэтому «CNN» и «высокое разрешение» — почти синонимы в практике агромониторинга: свёрточная сеть окупается там, где есть, что разглядывать. Подавать пиксели

Sentinel-2 10 м в тяжёлую сеть ради одной лишь моды — типичная ошибка новичка, которую этот модуль учит не совершать.

3. Перенос обучения: как обойти нехватку данных

Главный барьер CNN — потребность в размеченных данных — частично снимается **переносом обучения** (transfer learning). Идея: взять сеть, уже обученную на огромном наборе (ImageNet или, точнее для нас, геопространственные foundation-модели, публикуемые открыто на Hugging Face, [урок 2](#)), и *дообучить* её на своей небольшой задаче. Ранние слои такой сети уже умеют распознавать края и текстуры — это универсально, — и переучивать приходится в основном верхние слои под свои классы. Перенос обучения радикально снижает требования к объёму размеченных данных и времени обучения; для многих региональных задач это единственный практичный способ применить CNN при скромной выборке. Оговорка честности: модель, предобученная на обычных фотографиях, знает не совсем то, что нужно для мультиспектральных снимков, — поэтому предпочтительны предобучения именно на ДЗЗ, а результат в любом случае проверяется на своём тесте.

На практике перенос обучения имеет две «настройки глубины». Можно **заморозить** предобученные слои и обучать только новую «голову» под свои классы — это быстро и почти не переобучается, годится при совсем малых данных. Можно **разморозить** и дообучить всю сеть с маленькой скоростью обучения (fine-tuning) — это даёт больше качества, но требует больше данных и осторожности. Выбор между ними — тот же компромисс смещения и дисперсии: чем меньше ваша выборка, тем сильнее стоит опираться на замороженные чужие признаки. Для геопространственных foundation-моделей, предобученных на миллионах спутниковых сцен, даже замороженные признаки часто оказываются на удивление сильными — это делает CNN доступнее для региональных проектов с ограниченной разметкой, чем было ещё несколько лет назад. [UNVERIFIED: конкретный выигрыш зависит от модели, задачи и территории — проверяется экспериментом на своём тесте]

4. Метрики: как не обмануть себя цифрой

Модель обучена — как измерить, хороша ли она? Наивный ответ «доля верных пикселей» (accuracy) — одна из самых опасных ловушек прикладного ML, и умение её обходить отличает грамотную оценку от самообмана.

4.1 Почему accuracy лжёт при дисбалансе

Вспомним [урок 2](#): в агроландшафтах Северного Казахстана пашня занимает подавляющую площадь, а водоёмы или лесополосы — проценты. Модель, которая всё объявляет пашней, получит высокую общую точность — просто потому, что пашни

много, — и при этом будет полностью бесполезна: она не найдёт ни одного водоёма. Общая точность маскирует провал на редких, но важных классах. Поэтому в задачах с дисбалансом (то есть почти всегда в ДЗЗ) ассигасу сопровождают метриками, чувствительными к каждому классу.

4.2 Точность, полнота и F1

Для каждого класса вводят два понятия. **Точность** (precision) — из того, что модель назвала классом X, какая доля действительно X (мало ложных срабатываний).

Полнота (recall) — из всех реальных объектов класса X какую долю модель нашла (мало пропусков). Между ними компромисс: можно быть осторожным (высокая precision, низкий recall) или всеохватным (наоборот). **F1** — гармоническое среднее precision и recall, единая оценка баланса; её считают *по каждому классу отдельно*, а затем усредняют. Важно *как* усредняют: макро-F1 (простое среднее по классам) даёт редким классам тот же вес, что и частым, и потому честнее показывает, справляется ли модель со всем спектром классов, чем взвешенное по частоте среднее.

4.3 IoU — метрика границ для сегментации

Для сегментации ключевая метрика — **IoU** (Intersection over Union, индекс Жаккара): отношение площади пересечения предсказанной и истинной областей класса к площади их объединения. Наглядно: наложите предсказанный контур поля на истинный — IoU показывает, какую долю их суммарной площади занимает совпавшая часть; полное совпадение даёт 1, полное несовпадение — 0. IoU строго наказывает и за пропуски, и за «разлив» класса за его границы, поэтому это честная оценка качества именно *очертаний* объектов — то, что критично для карт полей. Средний IoU по классам (mIoU) — стандартная сводная метрика сегментационных моделей.

4.4 Каппа Коэна — поправка на случайность

Ещё одна тонкость сегментации: IoU можно считать по-разному усреднённым. Микро-усреднение (по всем пикселям сразу) даёт вес пропорционально площади и потому благоволит крупным классам; макро-усреднение (среднее IoU по классам) уравнивает классы и честнее отражает работу с редкими объектами. Как и с F1, выбор способа усреднения — содержательное решение, которое надо озвучить в отчёте, а не «настройка по умолчанию». Один и тот же результат сегментации может выглядеть отличным по микро-IoU и посредственным по макро-IoU — и оба числа правдивы, просто отвечают на разные вопросы.

Каппа Коэна отвечает на вопрос: насколько согласие модели с эталоном лучше случайного угадывания с учётом частот классов? Значение 0 означает «не лучше случая», 1 — идеальное согласие. В дистанционном зондировании каппа традиционно сопровождает матрицу ошибок как мера, устойчивая к дисбалансу: она не даст

обмануться высокой ассигасу на доминирующем классе. Интерпретировать абсолютное значение каппы следует осторожно и в контексте задачи — но как инструмент сравнения моделей на одних данных она полезна.

4.4a Какую метрику брать главной

Метрик много, и соблазн — отчитаться самой красивой. Профессиональный подход обратный: главную метрику выбирают до эксперимента, исходя из задачи и цены ошибок. Если одинаково важны все классы, включая редкие, — macro-F1 или mIoU. Если критично не пропустить конкретный класс (скажем, водоохранную зону) — recall этого класса. Если продукт — карта границ полей — mIoU. Общую точность оставляют как вспомогательный, легко читаемый заказчиком показатель, но никогда не как единственный критерий при дисбалансе. И всегда сообщают метрики *по классам*, а не только усреднённые: усреднение — тоже способ спрятать провал. Зафиксировать главную метрику заранее — та же дисциплина, что заморозить тест ([урок 2](#)): она не даёт задним числом подобрать ту цифру, которая выгоднее выглядит.

4.5 Матрица ошибок — источник всех метрик

Все перечисленные числа — свёртки одной таблицы. **Матрица ошибок** (confusion matrix) в строках содержит истинные классы, в столбцах — предсказанные; на диагонали — верные ответы, вне её — кто с кем спутан. Это самый информативный инструмент анализа: он не просто говорит «модель ошибается на 15%», а показывает *как именно* — например, что залежь систематически принимается за пастбище (агрономически осмысленная путаница) или что вода теряется в тени облаков (дефект данных). Читать матрицу ошибок обязан каждый, кто сдаёт карту заказчику: за одной цифрой качества всегда стоит структура ошибок, и именно она определяет пригодность продукта. Конкретные значения всех метрик вы получите в [практикуме](#) — лекция не приводит «эталонных» чисел, их не существует до эксперимента.

5. Анализ ошибок: от метрики к улучшению

Метрика говорит *сколько*, матрица ошибок — *что*, а анализ ошибок отвечает *почему и что делать*. Это, возможно, самый недооценённый навык прикладного ML: начинающие тратят недели на перебор моделей, тогда как один вдумчивый час над ошибочными примерами часто указывает точную причину и дешёвое лекарство. Практический цикл: найдите в матрице самую «дорогую» путаницу; посмотрите глазами на конкретные ошибочные примеры; выдвиньте гипотезу о причине. Частые причины и лекарства: *шум в метках* (класс размечен непоследовательно — вернуться к § 2 [урока 2](#), почистить эталоны); *нехватка примеров редкого класса* (собрать/дополнить, взвесить классы); *объективная неразличимость* на данном разрешении (нужен другой источник — БПЛА или сезонный ряд); *утечка данных* (подозрительно

высокие метрики — перепроверить разбиение). Ключевая мысль: рост качества чаще приходит от работы с *данными и постановкой задачи*, чем от смены или тонкой настройки модели. Это профессиональная зрелость — искать причину в данных прежде, чем менять алгоритм.

6. Честное сравнение трёх подходов

Теперь замкнём модуль. Три подхода — RF (таблица), MiniRocket (ряды), CNN (тайлы) — сравнимы честно только на *общем материале*: один район, одно пространственное разбиение, один набор метрик ([урок 2, § 5.1](#)). Именно так устроен [практикум](#).

Оговоримся, что «честное сравнение» — это не просто одинаковые данные, но и одинаковая добросовестность настройки. Сравнить тщательно оптимизированную CNN с Random Forest «по умолчанию» так же нечестно, как и наоборот: у каждого метода должна быть разумная, а не показная конфигурация, и решения о ней принимаются по валидации, а не по тесту. Ещё одна ловушка — сравнение по одной случайной выборке: разбиение вносит свою изменчивость, и разница в доли процента между моделями может быть просто шумом разбиения. Честный вывод часто звучит не «модель А лучше модели Б», а «в пределах изменчивости разбиения модели неразличимы, поэтому выбираем более простую и объяснимую». Такая формулировка — признак зрелости аналитика, а не его неуверенности.

Ось сравнения	Random Forest	MiniRocket	CNN (U-Net/ResNet)
Что «видит»	спектр пикселя (± соседние даты)	форму сезонной кривой	пространственный контекст, текстуру
Данные	сотни/класс	сотни рядов/ класс	тысячи тайлов (меньше с переносом)
Ресурсы	CPU, минуты	CPU, секунды– минуты	GPU, часы
Интерпретируемость	высокая (важность, уверенность)	средняя	низкая
Родная задача	классификация по признакам	классификация культур по	сегментация границ, высокое

Ось сравнения	Random Forest	MiniRocket	CNN (U-Net/ResNet)
		фенологии	разрешение
Слабость	нет контекста, «солит» карту	нужны выровненные ряды	данные, GPU, непрозрачность

Столбца «точность» здесь снова нет намеренно: какой подход победит по качеству — эмпирический вопрос конкретных данных, и вписать ответ заранее было бы фабрикацией. Практический алгоритм выбора: начните с Random Forest как базовой линии; если задача — культуры по фенологии, добавьте MiniRocket; переходите к CNN, когда решает пространственный контекст (высокое разрешение, важность формы и границ) и есть данные и GPU. Если сложная CNN не превосходит RF на честном тесте — выбирайте RF: простота, объяснимость и воспроизводимость на бесплатном стеке ценны для устойчивости проекта не меньше долей процента точности (урок 3, § 5.1).

Отдельно стоит сказать про **ансамбли и гибриды**. Подходы не обязаны конкурировать — их можно сочетать: например, признаки MiniRocket (форма кривой) вместе со спектральными и рельефными признаками подать в один Random Forest, объединив временную и спектральную информацию в интерпретируемой модели без GPU. Или использовать CNN для точных границ полей, а внутри каждого поля классифицировать культуру по ряду NDVI. Такие гибриды часто практичнее «чистых» решений, потому что берут сильные стороны каждого метода. Но и усложняют пайплайн — а значит, требуют той же честной оценки и того же вопроса «оправдана ли сложность». Модуль сознательно учит сначала уверенно владеть тремя базовыми подходами по отдельности; их комбинирование — естественное продолжение, к которому вы придёте на практике.

Наконец, помните про **сквозной инвариант платформы**, который в этой лекции обретает полную форму. Любая модель — RF, MiniRocket, CNN — производит гипотезу о территории, а не истину. Финальная проверка на пространственном тесте, чтение матрицы ошибок, анализ ошибочных примеров глазами, карта уверенности и, где возможно, полевая сверка — это и есть шаг «человек верифицирует», без которого результат модели не становится продуктом. ИИ и автоматика прошли весь модуль как ускоритель; ответственность за выводы осталась на человеке. Именно этот навык — не обучить модель, а обоснованно доверять или не доверять её результату — отличает инженера ДЗЗ от оператора кнопки «обучить».






Рис. 2. Дерево выбора архитектуры под задачу агромониторинга. Любая ветвь завершается проверкой на честном пространственном тесте с анализом матрицы ошибок. Alt: блок-схема принятия решения, ведущая от природы задачи к выбору MiniRocket, Random Forest или CNN, с обязательной финальной проверкой на тесте.

Региональный кейс

Ситуация: Управление сельского хозяйства района Северо-Казахстанской области заказало карту землепользования: четыре класса — пашня, пастбище/залежь, водные объекты, лесополосы/древесная растительность. Пашня и пастбище занимают почти всю площадь, водоёмы и лесополосы — единицы процентов. Команда обучила две модели (Random Forest на композите и U-Net на тайлах) и должна выбрать одну для сдачи.

Данные: медианный композит и тайлы Sentinel-2 L2A за сезон (урок 1); эталоны — верифицированная разметка (урок 2); пространственное разбиение по сетке.

Задача:

1. Почему общая точность (ассигасу) — плохой единственный критерий выбора в этой задаче, и какие метрики её заменяют?
2. По матрице ошибок обнаружено, что лесополосы систематически теряются (низкий recall), хотя ассигасу высока. Что это говорит о модели и что предпринять?
3. U-Net дал на пространственном тесте немного выше mIoU, но требует GPU и непрозрачен; RF чуть слабее, но объясним и работает в бесплатном Colab. Как обосновать выбор перед заказчиком?

Разбор: Ассигасу маскирует провал на редких классах (§ 4.1): модель, игнорирующая лесополосы, всё равно покажет высокую общую точность из-за доминирования пашни; заменяют её macro-F1, per-class recall, mIoU и каппой Коэна (§ 4.2–4.4). Потеря лесополос при высокой ассигасу — классический признак дисбаланса и/или нехватки примеров редкого класса; действия — взвешивание классов, дополнительная разметка лесополос, проверка, различимы ли они вообще на 10 м (§ 5). Выбор модели

— не только про метрику: если преимущество U-Net в пределах шума разбиения, а RF даёт объяснимость, карту уверенности и воспроизводимость на бесплатном стеке, для устойчивого проекта FOLUR разумнее RF (§ 6); если же критична точность границ узких объектов и есть ресурсы на сопровождение — U-Net. Конкретные значения метрик команда получает сама; лекция не подставляет несуществующих чисел.

Кейс полностью реализуется в [практикуме](#) и служит основой сценарного вопроса [итоговой оценки](#).

Закрепление и применение

Попробуйте в Colab

В ноутбуке урока (<URL будет назначен при создании репозитория ноутбуков>) обучите компактную U-Net на тайлах (по возможности — с переносом обучения) и постройте матрицу ошибок и per-class F1. Сравните их с метриками RF из [урока 3](#) на том же районе и разбиении. Какой класс каждый подход теряет чаще?

Границы применимости

CNN требуют GPU и тысяч меток; при скромной выборке без переноса обучения они легко переобучаются и уступают Random Forest. Accuracy без per-class метрик и матрицы ошибок вводит в заблуждение при дисбалансе классов. Каппа Коэна и IoU полезны для сравнения на одних данных, но их абсолютные значения нельзя переносить между задачами и территориями как «нормативы качества».

Что это даёт вашему хозяйству

Умение выбрать *минимально достаточную* модель экономит хозяйству и деньги, и время: часто задача решается Random Forest в бесплатном Colab, а не дорогой нейросетью на арендованном GPU. А привычка требовать матрицу ошибок и per-class метрики защищает от красивых, но пустых процентов в презентациях подрядчиков. Без-кодовая версия анализа — [модуль ПЗ](#).

Кейс для размышления

Подрядчик отчитался: «Точность классификации земель — 96%». Сформулируйте пять вопросов, которые обязан задать заказчик, прежде чем принять работу (подсказки: § 4.1 про дисбаланс, § 4.5 про матрицу ошибок, [урок 2](#) про разбиение и метки).

Проверь себя

Самопроверка · вариант слушателя **конспект** · вопросов: 4 · порог зачёта: 75%

1. Что показывает матрица ошибок такого, чего не даёт одно число метрики?

- ☐ Скорость обучения модели
- ☐ Структуру ошибок — какие классы с какими путаются (например, залежь принимается за пастбище)
- ☐ Важность признаков модели
- ☐ Только суммарную долю правильных ответов

2. Чем обучение свёрточных фильтров CNN принципиально отличается от преобразования MiniRocket?

- ☐ Фильтры CNN обучаются под задачу, а ядра MiniRocket фиксированы и не обучаются
- ☐ Между ними нет различий — это одно и то же
- ☐ CNN применима лишь к таблицам, а MiniRocket — к снимкам
- ☐ CNN работает только на CPU, а MiniRocket требует GPU

3. Аккуратно настроенная CNN не превзошла Random Forest на честном пространственном тесте. Разумное решение для устойчивого проекта FOLUR:

- ☐ Выбрать Random Forest — простота, объяснимость и воспроизводимость на бесплатном стеке ценнее недостижимого выигрыша в точности
- ☐ Отказаться от обеих моделей
- ☐ Всё равно внедрить CNN как более современную технологию
- ☐ Объединить обе в один сервис на GPU-сервере

4. Почему общая точность (ассигасу) обманчива при классификации земель Северного Казахстана?

- ☐ Ассигасу подходит только для регрессии, а не классификации
- ☐ Ассигасу невозможно вычислить для многоклассовых задач
- ☐ При доминировании пашни модель может игнорировать редкие классы (водоёмы, лесополосы) и всё равно показать высокую ассигасу

☐ Accuracy всегда занижает качество модели

Проверить

Контрольные вопросы

1. Дайте определения precision, recall, F1, IoU и каппы Коэна. (*Bloom: знать*)
2. Объясните, почему перенос обучения снижает требования к объёму размеченных данных. (*Bloom: понимать*)
3. Для задачи картирования лесополос вашего района Акмолинской области обоснуйте выбор между U-Net и Random Forest. (*Bloom: анализировать*)

Что дальше?

Модуль пройден: вы умеете найти данные, собрать выборку без утечек, обучить три класса моделей и честно сравнить их. Дальше — практика и проверка себя:

[практикум «Классификация землепользования тремя подходами»](#) собирает весь модуль в один проект на реальном районе СКО; [ИИ-задание](#) учит аудировать ML-пайплайн, собранный кодинг-агентом; [итоговая оценка](#) закрепляет компетенции. Связанные модули: [А4 — ML для водных объектов](#), [П3](#) и [П4](#) — профессиональные проекции.

Практикум: классификация землепользования района СКО тремя подходами (RF / MiniRocket / CNN)

Модуль **А3: ИИ и машинное обучение в агроэкологическом мониторинге**. Время выполнения: **60–90 мин.** Инструменты: Google Colab (Python), Google Earth Engine, scikit-learn, sktime, PyTorch — весь стек открытый и бесплатный. Данные: Sentinel-2 L2A (`COPERNICUS/S2_SR_HARMONIZED`), ESA WorldCover, границы района из OpenStreetMap. Ноутбук: `<URL будет назначен при создании репозитория ноутбуков>`.

Цель практикума

[Bloom: применять] Самостоятельно собрать обучающую выборку по одному району Северо-Казахстанской области, обучить и честно (с пространственным разбиением) сравнить три подхода к классификации землепользования — Random Forest, MiniRocket и компактную CNN — и обоснованно выбрать один из них под задачу карты.

Практикум сводит воедино все четыре лекции модуля: данные ([урок 1](#)), выборку без утечек ([урок 2](#)), классические модели ([урок 3](#)), CNN и метрики ([урок 4](#)). Итог — прикладной продукт модуля.

Что нужно ПОДГОТОВИТЬ

- [] Аккаунт Google и доступ к [Google Earth Engine](#) (бесплатная регистрация для исследователей).
- [] Google Colab (открывается в браузере, установка не нужна); желательно включить GPU в меню «Среда выполнения» для шага 5.
- [] Границу тестового района СКО в формате GeoJSON: возьмите административную границу района из OpenStreetMap (`geoBoundaries / Overpass`) или используйте готовый полигон из ноутбука.
- [] Библиотеки (устанавливаются первой ячейкой ноутбука): `earthengine-api`, `geemap`, `scikit-learn`, `sktime`, `torch`, `numpy`, `rasterio`.



Никаких реальных координат водоёмов

В этом практикуме работаем только с наземным землепользованием.

Батиметрические данные и координаты водоёмов — предмет [модуля A4](#) и подчиняются отдельному [правовому режиму данных](#); здесь они не используются.

Задание

Шаг 1. Определяем район и период (≈8 мин)

Задайте область интереса и вегетационное окно сезона по методике [урока 1](#).

```
import ee, geemap
ee.Authenticate(); ee.Initialize()

aoi = geemap.geojson_to_ee(district_geojson) # граница района СКО из OSM
start, end = '2023-05-01', '2023-09-30'      # сезон яровых
```

Ожидаемый результат: на интерактивной карте `geemap` отображается граница выбранного района СКО; переменная `aoi` — валидная геометрия.

Шаг 2. Строим безоблачный композит и ряды NDVI (≈12 мин)

```
def mask_scl(img):
    scl = img.select('SCL')
    good = scl.remap([4, 5, 6, 7], [1, 1, 1, 1], 0) # вегетация, почва, вода,
    unclassified
    return img.updateMask(good).divide(10000)

s2 = (ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED')
      .filterBounds(aoi).filterDate(start, end)
      .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 30))
      .map(mask_scl))

print('Сцен в выборке:', s2.size().getInfo()) # сколько сцен нашлось
composite = s2.median().clip(aoi)             # медианный композит

def add_ndvi(img):
    return img.addBands(img.normalizedDifference(['B8', 'B4']).rename('NDVI'))
ndvi_series = s2.map(add_ndvi).select('NDVI') # ряд NDVI для
MiniRocket
```

Ожидаемый результат: число сцен выведено в консоль; `composite` — многоканальный медианный композит по району; `ndvi_series` — коллекция NDVI по датам.



Контроль качества (человек верифицирует)

Выведите композит на карту (геемап.Мар) и посмотрите глазами: нет ли облачных артефактов, полос, «дыр». Если июнь пустой — зафиксируйте это: карта уверенности по месяцам обязательна в отчёте (урок 1, кейс).

Шаг 3. Метки и выборка без утечек (≈ 12 мин)

Черновые метки укрупнённых классов берём из ESA WorldCover и выборочно верифицируем (урок 2).

```
wc = ee.ImageCollection('ESA/WorldCover/v200').first().clip(aoi) # 10 м,
классы LULC

# Сетка 5×5 км для ПРОСТРАНСТВЕННОГО разбиения (не по пикселям!)
grid = aoι.coveringGrid('EPSG:3857', 5000)

# Собираем обучающую таблицу: признаки композита + метка WorldCover + id
ячейки сетки
sample = composite.addBands(wc.rename('label')).stratifiedSample(
    numPoints=300, classBand='label', region=aoι, scale=10, geometries=True)
```

Ожидаемый результат: таблица `sample` с признаками, меткой и координатами; каждой точке присвоен идентификатор ячейки сетки (группа для разбиения).



Проверка на утечку

Разбиение выполняется по **ячейкам сетки** (`GroupShuffleSplit` / `GroupKFold` по `cell_id`), а не случайно по точкам. Ниже (шаг 6) вы измерите цену утечки, сравнив два разбиения.

Шаг 4. Random Forest на пиксельной таблице (≈ 10 мин)

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GroupShuffleSplit
from sklearn.metrics import f1_score, cohen_kappa_score, confusion_matrix

gss = GroupShuffleSplit(n_splits=1, test_size=0.3, random_state=42)
tr, te = next(gss.split(X, y, groups=cell_id)) # пространственное
разбиение

rf = RandomForestClassifier(n_estimators=300, random_state=42).fit(X[tr],
y[tr])
pred = rf.predict(X[te])
print('macro-F1:', f1_score(y[te], pred, average='macro'))
print('kappa :', cohen_kappa_score(y[te], pred))
print(confusion_matrix(y[te], pred))
```

```
print('важность признаков:', sorted(zip(feature_names,
rf.feature_importances_),
                                   key=lambda t: -t[1])[:5])
```

Ожидаемый результат: значения macro-F1 и каппы, матрица ошибок, топ-5 важности признаков. Запишите их — это первая строка вашей сравнительной таблицы.

Шаг 5. MiniRocket на рядах NDVI и компактная CNN на тайлах (≈20 мин)

MiniRocket (классификация по фенологии, [урок 3](#)):

```
from sktime.transformations.panel.rocket import MiniRocket
from sklearn.linear_model import RidgeClassifierCV

mr = MiniRocket().fit(S_train)          # S_* — выровненные ряды NDVI
(декадная сетка)
clf = RidgeClassifierCV().fit(mr.transform(S_train), y_train)
pred_mr = clf.predict(mr.transform(S_test))  # тест — из ДРУГИХ ячеек сетки
```

Компактная CNN (сегментация тайлов, [урок 4](#)) — используйте готовую малую U-Net из ноутбука; при отсутствии GPU уменьшите число тайлов и эпох (задание останется выполнимым, метрики будут скромнее — это нормально).

Ожидаемый результат: метрики MiniRocket и CNN, вычисленные на том же пространственном тесте, что и RF. Три строки сравнительной таблицы заполнены.

Шаг 6. Цена утечки и честное сравнение (≈15 мин)

Обучите RF ещё раз со **случайным** разбиением (`train_test_split(..., random_state=42)`) и сравните метрики со шагом 4.

```
from sklearn.model_selection import train_test_split
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=42) #
СЛУЧАЙНО
rf2 = RandomForestClassifier(n_estimators=300, random_state=42).fit(Xtr, ytr)
print('macro-F1 (случайное разбиение):', f1_score(yte, rf2.predict(Xte),
average='macro'))
```

Ожидаемый результат: случайное разбиение почти наверняка даёт заметно более высокую метрику, чем пространственное. Эта разница — измеренная вами лично цена пространственной утечки ([урок 2](#), § 4.2). Запишите обе цифры и объясните разрыв.

Продукт задания

По итогам практикума у вас должно быть:

- [] Ноутбук с воспроизводимым пайплайном (сиды зафиксированы, окружение сохранено).
- [] Карта(ы) классификации землепользования района СКО (минимум — по лучшей модели).
- [] **Сравнительная таблица:** строки — RF, MiniRocket, CNN; столбцы — macro-F1, каппа, время обучения, ресурсы, замечания по матрице ошибок.
- [] Две цифры «цены утечки» (пространственное vs случайное разбиение) с объяснением.
- [] Письменное обоснование выбора одной модели под задачу карты (5–8 предложений).

Самопроверка: ваша сравнительная таблица не содержит «пустых» победителей — для каждого метода указано, почему он получил такие метрики (структура ошибок, объём данных, разрешение). Разрыв метрик между случайным и пространственным разбиением объяснён через автокорреляцию. Ни одно число в таблице не «придуманно» — все получены запуском кода.



Применить к своему хозяйству — «Проект на ВАШЕЙ земле»

Замените границу района на **контур своих полей** (нарисуйте в geojson.io или возьмите из QGIS, [модуль A2](#)). Соберите композит и метки WorldCover для своей территории, обучите Random Forest и постройте карту классов своих угодий с картой уверенности. Вопрос для осмысления: где модель не уверена — совпадает ли это с участками, которые и вам на местности кажутся спорными (краевые зоны, залежи в переходном состоянии)? Этот мини-проект — заготовка для профессионального [модуля П3](#) (без кода) и [П4](#) (первый Python-скрипт).

Дополнительные задания (по желанию)

1. Добавьте в признаки RF рельеф (уклон, экспозиция из ASTER GDEM) и фенологические признаки (амплитуда NDVI, дата пика) — изменилась ли важность и качество ([урок 3](#), § 3.4)?
2. Постройте карту уверенности RF (доля голосов деревьев) и сдайте её вместе с картой классов.
3. Повторите анализ для района Костанайской или Акмолинской области и сравните структуру ошибок между регионами.
4. Соберите гибрид: фенологические признаки MiniRocket + спектральные признаки в одном Random Forest ([урок 4](#), § 6).

Связи

- Лекции модуля: [урок 1](#), [урок 2](#), [урок 3](#), [урок 4](#).
- Следующий шаг: [ИИ-задание модуля](#) — аудит ML-пайплайна, собранного кодинг-агентом.
- Итоговая проверка: [assessment/final.md](#).
- Политика данных платформы: [Датасеты](#).

ИИ-ассистент в работе: аудит ML-пайплайна, собранного кодинг-агентом

Модуль **A3: ИИ и машинное обучение в агроэкологическом мониторинге**. Уровень ИИ-слоя: **Pro-code**. Время: **45–60 мин**. Инструменты: терминальный кодинг-агент (Claude Code / OpenCode — вендор-независимо), Python, scikit-learn, Colab. Рамка платформы: **ИИ-инструменты в обучении**.

Главное правило: ИИ ускоряет — человек верифицирует

Кодинг-агент за минуты пишет ML-пайплайн, на который вручную ушёл бы час. Но сгенерированный код может содержать методические дефекты, незаметные при беглом чтении и катастрофические на практике: утечку данных, ошибки метрик, «протекающую» предобработку. Ваша работа в этом задании — не написать код, а **проверить чужой** и найти в нём то, чему модуль вас научил распознавать.

Зачем это

Автономные ГИС-агенты и терминальные кодинг-агенты — подтверждённый фронтир отрасли (анализ трендов ИИ в ГИС-обучении, `plans/stage-1/03_folur-practices-analysis.md`): они уже генерируют и исполняют цепочки геообработки и ML-пайплайны. Инженер, который умеет ставить агенту задачу и *критически проверять результат*, работает в разы быстрее; инженер, слепо доверяющий сгенерированному коду, рано или поздно сдаёт заказчику модель с завышенными на бумаге и проваленными на деле метриками. Этот навык — прямое продолжение **урока 2** (§ 4.4, «как проверить чужой пайплайн на утечки») и **урока 4** (метрики и матрица ошибок).

Цель задания

[Bloom: анализировать] Поставить кодинг-агенту задачу собрать ML-пайплайн классификации землепользования «split → train → validate», затем провести ревью сгенерированного кода, найти и исправить методические дефекты (в первую очередь утечку данных и ошибки метрик), и подтвердить корректность независимой проверкой.

Пошаговое задание

Шаг 1. Поставьте задачу агенту (≈10 мин)

В терминальном кодировщике (Claude Code, OpenCode или открытом аналоге) сформулируйте задачу на естественном языке. Пример промпта:

```
«Собери на scikit-learn пайплайн классификации землепользования по пиксельной
таблице признаков Sentinel-2 ( features.csv : спектральные каналы, NDVI за
несколько дат, метка класса, field_id , cell_id ). Нужно: загрузка данных,
разбиение train/test, обучение Random Forest, отчёт метрик. Сделай код
воспроизводимым.»
```

Намеренно **не подсказывайте** агенту про пространственное разбиение — вы проверяете, учтёт ли он его сам. Сохраните сгенерированный код без правок.

Шаг 2. Ревью по контрольному списку (≈15 мин)

Пройдите сгенерированный код по досмотровому списку из [урока 2](#) (§ 4.4). Для каждого пункта запишите вердикт «чисто / дефект» с цитатой строки:

1. **Разбиение.** Использован ли `train_test_split` без групп на пиксельных/полевых данных? Есть ли `groups=` / `GroupShuffleSplit` по `field_id` / `cell_id`? → Отсутствие групп = **пространственная утечка**.
2. **Предобработка.** Где вычисляются статистики нормализации — до или после разбиения? Обёрнуто ли в `Pipeline`? → Fit скейлера на всей выборке = **утечка через предобработку**.
3. **Метрики.** Отчитывается ли код только `accuracy`? Есть ли `macro-F1`, `каппа`, матрица ошибок? → Только `accuracy` при дисбалансе = **ошибка метрики** ([урок 4](#), § 4.1).
4. **Признаки.** Нет ли среди признаков столбца, производного от метки (та же карта, что дала `label`)? → **Утечка через метку**.
5. **Использование теста.** Сколько раз код обращается к тесту? Не подбираются ли по тесту гиперпараметры? → Настройка по тесту = **утечка выбора модели**.
6. **Воспроизводимость.** Зафиксированы ли сиды? Сохранены ли индексы разбиения?

Шаг 3. Исправьте дефекты (≈10 мин)

Отредактируйте код (сами или поручив агенту точечные правки с вашим контролем): замените случайное разбиение на групповое по `cell_id`, оберните предобработку в `Pipeline`, добавьте `macro-F1`, `каппу` и матрицу ошибок, уберите признаки-утечки.

Каждую правку обоснуйте ссылкой на конкретный раздел лекции.

Шаг 4. ОБЯЗАТЕЛЬНАЯ ВЕРИФИКАЦИЯ РЕЗУЛЬТАТА ИИ (≈15 мин)

Это ядро задания — без него оно не засчитывается. Верификация выполняется тремя независимыми способами, а не «на глаз»:

1. **Тест на утечку.** Обучите исправленный пайплайн дважды — со случайным и с пространственным разбиением — и сравните метрики. Значительный разрыв подтверждает, что исходный (случайный) вариант агента был оптимистичен. Зафиксируйте обе цифры.
2. **Матрица ошибок.** Постройте её и убедитесь, что высокая ассигасу (если она есть) не скрывает провал на редких классах. Прочитайте структуру ошибок — какие классы путаются.
3. **Контрольный участок глазами.** Примените модель к небольшому участку, где вы знаете землепользование (свои поля или хорошо дешифрируемый фрагмент), и визуально сверьте предсказание с реальностью. Модель, отличная по метрикам, но абсурдная на знакомом участке, — сигнал скрытого дефекта.

Запишите результаты всех трёх проверок. Если хоть одна выявила проблему — вернитесь к шагу 3.

Критерии зачёта

Задание засчитано, если вы:

- [] поставили задачу агенту и сохранили исходный сгенерированный код;
- [] прошли весь досмотровый список и нашли **минимум одну реальную утечку или ошибку метрики** (в промпте она спровоцирована намеренно — отсутствие групп в разбиении);
- [] исправили дефекты, обосновав каждую правку ссылкой на раздел лекции;
- [] выполнили **все три** способа верификации и привели их результаты (две цифры «цены утечки», матрицу ошибок, вывод по контрольному участку);
- [] сформулировали письменный вывод: какие дефекты типичны для сгенерированного ML-кода и почему верификация обязательна.



Вендор-независимость и работа без ИИ

Задание выполнимо с любым кодинг-агентом (Claude Code, OpenCode, открытые аналоги) и **полностью без ИИ**: во втором случае вы сами пишете заведомо «протекающий» пайплайн (простой `train_test_split`), а затем аудируете и чините собственный код по тому же списку. Навык верификации важнее конкретного инструмента.



Научная честность

Не принимайте метрики, сгенерированные агентом, на веру и не переписывайте их в отчёт как факт — любое число должно быть воспроизведено вашим запуском. Агент может «галлюцинировать» и правдоподобные, но неверные значения; ваша подпись под отчётом означает, что вы это проверили.

СВЯЗИ

- Основа: [урок 2](#) (§ 4.4 — досмотр пайплайна на утечки), [урок 4](#) (метрики, матрица ошибок).
- Практика данных: [практикум модуля](#) (шаг 6 — цена утечки).
- Рамка ИИ-слоя платформы: [ИИ-инструменты в обучении](#).
- Профессиональные проекции: [П3 — ИИ без программирования](#), [П4 — Python с ИИ-напарником](#).

Итоговая оценка модуля А3: банк вопросов и сценарный кейс

Модуль **А3: ИИ и машинное обучение в агроэкологическом мониторинге**. Время: **~30 мин.** Формат: автопроверяемые MCQ (тест-движок платформы) + сценарный кейс-вопрос прозой. **Порог сертификации — 75%.** Все задания охватывают четыре лекции и практикум модуля.

Как устроена оценка

Итоговая оценка состоит из двух частей. **Часть А** — банк из 10 вопросов с выбором ответа (два тематических блока), проверяет знание и понимание ключевых концепций модуля. **Часть В** — сценарный кейс-вопрос, где вы прозой рассуждаете как аналитик; это образец сценарной части экзамена, которую проверяет эксперт. Для сертификации нужно набрать **не менее 75%** по совокупности; сценарная часть оценивается по рубрике (см. ниже).

Научная честность в ответах

Ни один вопрос не требует «выучить» конкретное значение точности модели — таких эталонов не существует до эксперимента. Оценивается ваше понимание методологии, а в сценарной части — способность обосновать решение, а не назвать «правильное число».

Часть А. Банк вопросов (10 MCQ)

Блок 1. Данные и выборка (уроки 1–2)

Самопроверка · вариант слушателя **конспект** · вопросов: 4 · порог зачёта: 75%

1. Случайное разбиение пиксельной выборки на train/test завышает оценку качества, потому что:

- ☐ Соседние почти одинаковые пиксели одного поля попадают и в train, и в test (пространственная утечка)

- ☐ Случайное разбиение уменьшает обучающую выборку
- ☐ Случайное разбиение нарушает баланс классов
- ☐ Пиксели теряют геопривязку при перемешивании

2. Задача — ретроспектива землепользования участка с 1998 года.

Какой источник данных единственно пригоден?

- ☐ Landsat — непрерывный архив с 1970–80-х годов
- ☐ MODIS — ежедневная съёмка с 2000 года
- ☐ ESA WorldCover — глобальная карта покрытия
- ☐ Sentinel-2 — архив с 2015 года, разрешение 10 м

3. Почему метки из ESA WorldCover непригодны для обучения классификатора культур (пшеница/ячмень/пар)?

- ☐ Метки из готовых карт нельзя использовать в принципе
- ☐ WorldCover имеет слишком грубое разрешение (250 м)
- ☐ WorldCover распространяется на платной основе
- ☐ Легенда WorldCover не различает культуры — класс «cropland» един для всех

4. Стандарт STAC ценен для инженера ML-систем прежде всего потому, что:

- ☐ Он автоматически исправляет ошибки облачных масок
- ☐ Это открытый единый язык каталогов — код поиска переносим между MPC, CDSE и другими, без привязки к вендору
- ☐ Он даёт доступ к данным без регистрации
- ☐ Он гарантирует самое высокое разрешение снимков

Проверить

Блок 2. Модели, метрики, выбор архитектуры (уроки 3–4)

Самопроверка · вариант слушателя **конспект** · вопросов: 4 · порог зачёта: 75%

1. Аккуратно настроенная CNN не превзошла Random Forest на честном пространственном тесте. Обоснованное решение для устойчивого проекта FOLUR:

- ☐ Отказаться от обеих моделей
- ☐ Выбрать Random Forest — объяснимость и воспроизводимость на бесплатном стеке важнее недостижимого выигрыша
- ☐ Внедрить CNN как более современную технологию
- ☐ Объединить обе модели на арендованном GPU-сервере

2. Для различения культур по сезонной динамике NDVI предпочтителен MiniRocket, а не Random Forest на датах-столбцах, потому что:

- ☐ MiniRocket всегда точнее деревьев на любых задачах
- ☐ Random Forest не работает с индексом NDVI
- ☐ MiniRocket требует GPU и потому мощнее
- ☐ MiniRocket видит форму временного ряда, а дерево трактует даты как несвязанные столбцы

3. Общая точность (ассурасу) обманчива при классификации земель Северного Казахстана, потому что:

- ☐ Ассурасу применима только к регрессии
- ☐ Ассурасу всегда занижает качество
- ☐ При доминировании пашни модель может игнорировать редкие классы и всё равно показать высокую ассурасу
- ☐ Ассурасу нельзя вычислить для многоклассовых задач

4. Что даёт матрица ошибок сверх одного числа метрики?

- ☐ Важность признаков модели
- ☐ Структуру ошибок — какие классы с какими путаются
- ☐ Только суммарную долю верных ответов
- ☐ Скорость обучения модели

Проверить

Часть В. Сценарный кейс-вопрос (проза)

Прочитайте сценарий и напишите развёрнутый ответ (ориентир — 250–400 слов). Это образец сценарной части экзамена; ответ оценивает эксперт по рубрике ниже.

Сценарий. Управление сельского хозяйства района Северо-Казахстанской области заказало у подрядчика карту землепользования (классы: пашня, пастбище/залежь, водные объекты, лесополосы) на основе Sentinel-2. Подрядчик отчитался одной строкой: «Точность классификации — 96%, использована нейросеть». Лесополосы и водоёмы занимают в районе единицы процентов площади. Вы — независимый эксперт, которого попросили оценить работу до приёмки и оплаты.

Задание. Сформулируйте аргументированное заключение:

1. Почему заявленной цифры «96%» недостаточно для приёмки и какие метрики и материалы вы обязаны запросить (свяжите с дисбалансом классов и матрицей ошибок)?
2. Как проверить, что оценка качества не завышена пространственной утечкой данных? Какой конкретный тест это покажет?
3. Какие вопросы о метках и обучающей выборке вы зададите подрядчику?
4. При каких условиях выбор нейросети обоснован, а при каких разумнее была бы более простая модель — и как это связано с устойчивостью проекта FOLUR?
5. Какую роль в приёмке играет визуальная сверка на контрольном участке («человек верифицирует»)?

Рубрика оценки части В (эксперт)

Критерий	Что ожидается
Метрики и дисбаланс	Указано, что accuracy маскирует провал на редких классах; запрошены macro-F1, per-class recall, IoU, каппа, матрица ошибок
Проверка на утечку	Предложено сравнение пространственного и случайного разбиения; назван механизм автокорреляции
Качество данных	Заданы вопросы об источнике меток, их верификации, схеме разбиения, репрезентативности выборки
Обоснование выбора модели	Разведены случаи оправданной CNN и достаточно простого метода; связь с объяснимостью и нулевой инфраструктурой FOLUR

Критерий	Что ожидается
Верификация человеком	Указана роль визуальной сверки на контрольном участке и карты уверенности

Полный ответ, покрывающий все пять критериев с опорой на методологию модуля (без выдуманных чисел), соответствует зачёту сценарной части.

Связи

- Лекции: [урок 1](#), [урок 2](#), [урок 3](#), [урок 4](#).
- Практика: [практикум модуля](#), [ИИ-задание](#).
- Порог сертификации платформы — 75%; формат квизов конвертируется тест-движком платформы.